

דו"ח ייזום ותכנון מערכת RealEyes

זיהוי Deepfake in images

סטודנטים מגישים:

נועם דהן, עדן כהן, גל טייב

מנחות הפרויקט:

ד"ר אירינה רבייב

ד"ר אלונה קוצ'י

תאריך הגשה:

23.1.2025

לעדכן תוכן עניינים לאחר סיום עדכון: הערות עם [1]
ספר הפרויקט

תוכן עניינים:

3	1. מבוא וסקר ספרות
3	1.1. הגדרת Deepfake והמוטיבציה לזיהויו
3	1.2. שיטות ליצירת Deepfake ומודלים גנרטיביים GANs
4	1.3. גישות מרכזיות לזיהוי Deepfake
6	1.4. אתגרי אמינות ופערי מחקר
8	2. ייחוס: מטרות, יעדים ואיסוף מידע
8	2.1. רקע כללי
8	2.2. הגדרת הבעיה
9	2.3. מטרות ויעדים
9	2.4. חלופות (Alternative Approaches)
11	2.5. משתמשים עיקריים ובעלי עניין (Stakeholders)
14	2.6. פיצ'רים, סיפורי משתמש ודרישות לפיתוח
18	2.7. מצב קיים וחלופות הקיימות בשוק -
19	2.8. חוקים ואילוצים
21	2.9. צרכי משתמשים
21	2.10. סיכונים
27	3. עיצוב ודרישות
27	3.1. הגדרת פרסונות (Personas)
27	3.2. דרישות פונקציונליות (Functional Requirements)
29	3.3. דרישות לא-פונקציונליות (Non-Functional Requirements)
30	3.4. תהליכי אבטחה
30	3.5. עומסים ונפחים (Load & Capacity)
35	4. שיטה
35	4.1. סביבת הפיתוח ובסיס הנתונים
39	4.2. ארכיטקטורה (סיכום ברמת שיטה)
41	4.3. כלי פיתוח, כלי בדיקות ופיילוט
42	4.4. מערכת הפעלה וסביבת הרצה
42	4.5. תקשורת
43	4.6. פרוטוקול אבטחה
45	רשימת מקורות - References

1. מבוא וסקר ספרות

סקירה זו נועדה לסקור את ההתפתחויות האחרונות בזיהוי תוכן סינתטי מסוג Deepfake, תוך התמקדות בשיטות פורמיות, אתגרי הכללה ועמידות, והשלכות על אמינות מערכות זיהוי.

1.1. הגדרת Deepfake והמוטיבציה לזיהוי

המונח Deepfake מתייחס לתוכן סינתטי (תמונה, וידאו או אודיו) שנוצר על ידי רשתות נוירונים (Heidari et al, 2023). מערכות אלו לומדות דפוסים סטטיסטיים מורכבים מתוך מאגרי מידע ויזואליים וקוליים ומסוגלות לייצר תוכן מזויף ברמת ריאליזם גבוהה.

יכולות אלו כוללות מניפולציה על זהויות קיימות (כגון Face Swap), אך גם יצירה של דמויות אנושיות וסביבות חדשות לחלוטין שמעולם לא היו קיימות במציאות (Nguyen-Le et al, 2025).

הצורך בפיתוח שיטות זיהוי נובע מהאיום הגובר ש-Deepfakes מציבים, העלול לשמש למטרות זדוניות כמו הונאה פיננסית, הפצת מידע כוזב, התערבות בבחירות או פעילות נקם (Wang et al, 2024). הקושי של העין האנושית להבדיל בין תוכן אמיתי למזויף מדגיש את הדחיפות בפיתוח כלים אוטומטיים ואמינים לזיהוי (Wang et al, 2024).

1.2. שיטות ליצירת Deepfake ומודלים גנרטיביים GANs

מודל **Generative Adversarial Networks - GANs** הם הטכנולוגיה הדומיננטית מאחורי יצירת Deepfakes (Heidari et al, 2023). מודל GAN פועל על עקרון תחרותי בין הגנרטור (Generator) למבחין (Discriminator) המשתפרים בהדרגה עד שהזיופים נראים ריאליסטיים לחלוטין (Ye et al, 2024).

תהליך האימון של ה-GAN הוא תחרותי ומתנהל בשני שלבים מקבילים:


הגנרטור (Generator): מקבל וקטור רעש אקראי (Latent Vector) ומנסה להמיר אותו לתוכן ויזואלי כלומר לתמונה מזויפת. מטרתו היא לשפר את איכות הזיוף כך שייראה אמיתי ככל האפשר.

המבחין (Discriminator): מקבל תערובת של תמונות אמיתיות ותמונות מזויפות מהגנרטור. מטרתו היא ללמוד להבחין בצורה מדויקת ככל האפשר האם הקלט הוא אותנטי או סינתטי.

בתהליך האימון, שני הרכיבים משתפרים בהדרגה:

המבחין מספק אות שגיא שמכוון את הגנרטור לשיפור, והגנרטור משפר את הזיופים שלו. התהליך נמשך עד שהגנרטור מצליח "לרמות" את המבחין, כלומר, הזיופים נראים ריאליסטיים לחלוטין.

האיור הבא מציג ארכיטקטורת GAN (עיבוד עצמי, מבוסס על Heidari et al, 2023)



1.3. גישות מרכזיות לזיהוי Deepfake

הזיהוי הפסיבי של Deepfakes מתמקד בניתוח המאפיינים הפנימיים של המדיה הסינתטית כדי להבחין בינה לבין תוכן אותנטי (Nguyen-Le et al., 2025). רוב המחקר מתמקד בזיהוי וידאו Deepfake באמצעות מודלי DL.

1.3.1. ניתוח תחום התדרים (Frequency Domain Analysis)

גישה זו מזהה את "חתימות התדר" הבלתי נראות שהמודלים הגנרטיביים מותירים (Ye et al., 2024). חוקרים מצאו שבעת יצירת תמונות GAN נוצרים דפוסים מחזוריים ורעש מלאכותי בתדרים הגבוהים. כמו כן, גישה זו רלוונטית לזיהוי עקבות ייחודיות המושארות על ידי מודלי דיפוזיה (Diffusion Models) מתקדמים (Nguyen-Le et al., 2025).


חתימות אלו נובעות בעיקר מתהליך ה-upsampling:

כאשר מודל GAN יוצר תוכן, הוא מתחיל ממדיום קטן כמו תמונה ברזולוציה נמוכה ומגדיל אותה בהדרגה על ידי ניחוש ושחזור מלאכותי של פיקסלים חסרים.

תהליך שיחזור מלאכותי זה יוצר דפוסים מבניים קטנים - כגון רעש מחזורי, קווים עדינים או חוסר אחידות ספקטרלית הנמצאים בעיקר בתדרים הגבוהים ואינם קיימים במדיה אותנטית שצולמה במצלמה אמיתית. חשיפת ההבדלים הספקטראליים האלה באמצעות ניתוח מתמטי מספקת בסיס חזק לאלגוריתמי זיהוי.

במחקר של (Ye et al., 2024), הוצגה השוואה בין תמונה אמיתית לתמונות שנוצרו בשיטות שונות של הגדלה (upsampling). בעוד ששיטת Transposed Convolution יוצרת פרטים חדים אך עם רעש בתדרים הגבוהים, השיטה Up-sampling + Convolution יוצרת תמונות רכות מדי, נטולות פרטים עדינים (ראו דוגמה באיור 2).

Figure 2



איור 2 - השוואה בין תמונה אמיתית (a) לבין תמונה (b) שנוצרה בשיטת Transposed Convolution ותמונות (c-e) שנוצרו בשיטות Up-sampling (מתוך: (Ye et al., 2024)

הדגמה זו ממחישה כיצד ניתן לזהות הבדלים ספקטראליים אלו ולנצלם לצורך זיהוי זיופים ויזאליים.

1.3.2. איתור עקבות קונבולוציה ורעש (Convolutional Traces and Noise)


מודלי Deepfake משאירים עקבות ספציפיות המקושרות לארכיטקטורת הרשת שיצרה אותם. עקבות קונבולוציה (CTs) (Nguyen-Le et al., 2025). אלו משמשות לא רק לזיהוי עצם הזיוף, אלא גם לייחוס (Attribution) - היכולת לקבוע איזה גנרטור ספציפי יצר את המדיה. יכולת הייחוס חיונית ליישומים פורבניים מתקדמים. כאשר בנוסף, שיטות פורבניות מנצלות מודלי רעש (SRM) כדי לזהות דפוסים רעש לא טבעיים שהייצור הסינתטי מותיר (Nguyen-Le et al., 2025).

1.3.3. מודלים מתקדמים של למידה עמוקה (DL Models)

- **CNNs**: רשתות קונבולוציה (CNN) הן הכלי הנפוץ ביותר לזיהוי, בזכות יכולתן לחלץ מאפיינים מרקמיים (טקסטורה) וסטטיסטיים עדינים (Heidari et al, 2023).
- **Transfer Learning - TL**: השימוש ב-TL קריטי לשיפור יכולת ההכללה (Generalization) של המודלים וכן להתמודדות עם מחסור בנתוני אימון מגוונים. TL מאפשר העברת ידע ממודלים מאומנים על סטים גדולים למשימת הזיהוי, ובכך משפר משמעותית את היכולת לזהות זיופים שנוצרו בטכניקות חדשות (Nguyen-Le et al, 2025).
- **מנגנוני קשב (Attention Mechanisms)**: מגמות מחקר מתקדמות משלבות מנגנוני קשב כדי להתגבר על מגבלות ה-CNN, אשר מתמקדים רק במאפיינים מקומיים. מנגנונים אלו, כדוגמת מנגנון ה-Dual Attention (שהוצג במחקרם של Li et al, 2024), מאפשרים למודל ללכוד הקשרים גלובליים בין חלקי התמונה. הם עושים זאת על ידי קשב למיקום (חיבור פיקסלים רחוקים) וקשב לערוצים (הדגשת מאפיינים רלוונטיים), ובכך מאפשרים שילוב חיוני בין הרמזים הפורנזיים-מקומיים (כמו עקבות תדר) לבין חוסר עקביות רחב יותר בתמונה המזויפת (כגון חוסר תיאום אור/צל). השימוש ב-Attention מחזק את יכולת המודל לבצע אבחנה מדויקת יותר ומשפר את האמינות הכוללת.

1.3.4. זיהוי מולטימודלי והיברידי

זיהוי מולטימודלי משלב מידע ממקורות שונים (ויזואלי, אודיו או מטא-דאטה) כדי להגביר את האמינות (ראו דוגמה באיור 3; Li et al, 2024). ניתן לזהות זיופים על ידי חיפוש אי-התאמה אודיו-ויזואלית בין הפנים המעוותות לבין אות האודיו הנלווה. גישות היברידיות, המשלבות רמזים פורנזיים (כמו ניתוח תדרים ו-CTs) עם כוח החישוב של DL, הן כיוון מחקר מבטיח (Wang et al, 2024).



איור 3: ארכיטקטורת רשת מולטימודלית (DAFSVND) המשלבת עיבוד מקבילי של ערוצי וידאו, אודיו וטקסט (Li et al, 2024).

1.4. אתגרי אמינות ופערי מחקר

אחד האתגרים הקריטיים בתחום הוא המעבר מדיוק בתנאי מעבדה לאמינות (Reliability) בשימוש בעולם האמיתי, הנבחנת לאור שלושת אתגרי הליבה: הכללה, עמידות ופירוש (Wang et al, 2024). כפי שניתן לראות באיור 4, אמינות זו נבחנת לאור שלושת אתגרי הליבה: יכולת הכללה (Transferability), יכולת פירוש (Interpretability) ועמידות בתנאי שטח (Wang et al, Robustness, 2024).

1.4.1. הכללה (Generalization)

הכללה מתייחסת ליכולת של המודל לשמור על ביצועים אמינים כאשר הוא נתקל בטכניקות יצירה חדשות או במערכי נתונים שלא נראו באימון (Cross-Dataset) (Wang et al., 2024). מודלים רבים מאבדים עשרות אחוזים בדיוק כאשר הם נבחנים על מאגר שונה מזה שעליו אומנו, מה שמדגיש את חוסר החוסן שלהם לטכניקות ייצור מתפתחות (Nguyen-Le et al., 2025).

1.4.2. עמידות (Robustness) כנגד דחיסת רשתות חברתיות


עמידות היא יכולת המודל לשמור על ביצועים גבוהים גם כאשר הקלט עובר הפרעות ושינויים. האתגר החמור ביותר בתחום זה נובע מעיבוד פוסט-פרוססינג המבוצע אוטומטית על ידי פלטפורמות שיתוף מדיה (כגון Facebook, Flickr, Twitter ו-WhatsApp) בעת העלאת תכנים (Pasquini et al., 2021). בניגוד להפרעות אקראיות, פלטפורמות אלו מבצעות שינויים מבניים במידע: הן דוחסות את התמונה באופן אגרסיבי (Lossy Compression) באמצעות שינוי טבלאות הקוונטיזציה (Quantization Tables) ולעיתים קרובות אף מקטינות את הרזולוציה (Down-sampling). תהליכים אלו מטשטשים את ה"עקבות הפרנזיים" העדינים (Artifacts) שעליהם מסתמכים הגלאים, ועלולים למוטט לחלוטין את יכולת הזיהוי של מודלים קיימים (Nguyen-Le et al., 2025).

קונפליקט הכללה-עמידות: קיים קונפליקט מוכח תיאורטית ואמפירית בין יכולת המודל להכליל לבין יכולתו להיות עמיד בפני הפרעות פוסט-פרוססינג. מציאת פתרון יציב לשני האתגרים במקביל היא הפער המחקרי המרכזי בתחום (Wang et al., 2024).

1.4.3. פירוש (Interpretability) ויעילות חישובית

לצד הדיוק והעמידות, קיים צורך מהותי בפירוש החלטות המודל. רשתות נוירונים פועלות לרוב כ"קופסה שחורה", אך ביישומים פורנזיים ומשפטיים, סיווג תמונה כ"מזויפת" אינו מספק ללא הסבר נלווה (Wang et al., 2024). האתגר כיום הוא לפתח מודלים שלא רק מסווגים, אלא גם מספקים אינטרפרטציה ראייתית (Evidence Interpretation) – למשל, על ידי יצירת מפות חום המצביעות ויזואלית על האזורים המניפולטיביים בתמונה שגרמו להחלטה. בנוסף, קיים צורך בפיתוח מודלים בעלי יעילות

חשובית גבוהה שיאפשרו ביצועים בזמן אמת, במיוחד בסרטוני וידאו ארוכים הדורשים משאבי עיבוד רבים (Heidari et al., 2023).



איור 4: שלושת האתגרים המרכזיים בגילוי Deepfake כפי שהוגדרו בספרות: הכללה לנתונים חדשים (למעלה), יכולת פירוש והסבר ההחלטה (במרכז), ועמידות להפרעות רשת ומדיה חברתית (למטה). (מתוך: Wang et al. 2024)

1.5. סיכום והמלצות

פער מחקרי ופתרון מוצע: סקירת הספרות מראה כי קיים מחסור במודל היברידי ממוטב - כלומר, מודל המשלב בין יכולות הלמידה החזקות של רשתות עמוקות (Deep Learning) לבין רמזים פורכזיים קלאסיים (כגון ניתוח רעשים או התמרות תדר). שילוב זה נדרש כדי לספק הכללה חזקה כנגד גנרטורים מתפתחים, תוך שמירה על עמידות גבוהה כנגד דחיסת רשתות חברתיות.

בהתאם לכך, מטרת הפרויקט שלנו היא לפתח מודל חזק ומדויק, המשולב ממספר שיטות קיימות, לצורך זיהוי אמינות תמונות. כלומר, הבחנה מדויקת בין תוכן אמיתי לתוכן מזויף.

המלצות מרכזיות הנגזרות מהחקר ספרות:

כדי להבטיח את אמינותו ורלוונטיות המודל לעולם האמיתי, נדרש להתמקד בדרישות המפתח הבאות:

- מדדי הערכה מחמירים: חיוני למדוד את ביצועי המודל לא רק במונחי דיוק (Accuracy), אלא בעיקר במונחי הכללה (Generalization) על מערכי נתונים חיצוניים ועמידות (Robustness) כנגד סימולציות של דחיסה ושינויי איכות (כדי לדמות Post-processing).

- פירוש (Interpretability) והסבר: מומלץ לשקול כיצד המודל יכול לספק פירוש להחלטותיו (לדוגמה, על ידי הדגשת האזור המזויף בתמונה), כדי לחזק את האמינות הפורנזית שלו עבור שימוש בבתי משפט או לצורך בדיקת עובדות.

2. ייזום: מטרות, יעדים ואיסוף מידע

2.1 רקע כללי

חזון המוצר: עבור עיתונאים, חוקרים, גופי ביטחון ואזרחים המעוניינים לאמת תמונות, שרצונם הוא לזהות תמונות מזויפות (Deepfake) בצורה אוטומטית, מהירה ומהימנה- המוצר שלנו יכול לסייע להם באמצעות מערכת לזיהוי Deepfake בתמונות סטילס. שלא כמו כלים כלליים לזיהוי תוכן סינתטי שאינם מותאמים להקשרים מלחמתיים, המוצר שלנו הוא מערכת היברידית המשלבת ניתוח תדרים (CNN-SRM), ניתוח ויזואלי (EfficientNetB0) ו-Ensemble Learning, עם דגש על זיהוי זיופים בתמונות מלחמה. התקדמות מהירה בתחום הבינה המלאכותית, ובפרט בטכנולוגיות גנרטיביות כמו GANs ו-מודלי דיפוזיה, הביאה ליכולת מרשימה ליצור תמונות מזויפות שנראות אמיתיות לחלוטין. תופעה זו, המוכרת בשם Deepfake, אינה מוגבלת עוד ליצירת וידאו - כיום ניתן ליצור תמונות סטילס שנראות אותנטיות, לעיתים עד לרמת דיוק שהעין האנושית אינה מסוגלת לזהות כזיוף.

במקביל ליתרונות הטכנולוגיים של Deepfake, התופעה מייצרת איומים משמעותיים: הפצת דיסאינפורמציה, פגיעה באמינות גופי חדשות, יצירת ראיות מזויפות, הטעיית הציבור בזמן משברים ביטחוניים, פגיעה בפרטיות ובביטחון האישי. ככל שהאלגוריתמים אשר משמשים לייצור תמונות מתקדמים, כך היכולת לזהות זיופים הופכת למאתגרת יותר.

לכן, עולה צורך דחוף במערכות אוטומטיות, מדויקות וידידותיות לשימוש, אשר מסוגלות לנתח תמונה ולהעריך האם מדובר ביצירה אמיתית או זיוף שנמצא באמצעות מודלים גנרטיביים.

במסגרת הפרויקט אנו מבצעים מחקר השוואתי שמטרתו לבחון את יכולת ההכללה (Generalization) של ארכיטקטורות שונות לזיהוי Deepfake.

שאלת המחקר המרכזית היא: האם מודל למידה עמוקה שאומן על מאגר נתונים אחד שומר על ביצועי זיהוי מהימנים כאשר הוא נבחן על מאגר נתונים שונה, שלא נכלל בתהליך האימון (Cross-Database Generalization)?

שאלה זו רלוונטית ישירות לשימוש בעולם האמיתי, שבו מודל אינו יכול להיחשף מראש לכל סוג זיוף או מקור תמונה אפשרי. בשלב מוקדם של הפרויקט נבחנו ארכיטקטורות Xception כמודל ה-Spatial Analysis הראשי. אולם עקב עומס זיכרון GPU חריג שגרם לקריסת השרת לאחר שני epochs בלבד, התקבלה החלטה עקרונית לאמץ גישת *Lightweight Models* לכלל הניסויים. הארכיטקטורות שנבחרו לטובת הניסויים - *ViT-Light-10CNN-SRM*, *EfficientNetB*, ארכיטקטורות אלו עומדות בשני קריטריונים מרכזיים: ראשית, יעילות חישובית הן באימון (פחות פרמטרים, עלות אימון נמוכה יותר) והן באינפרנס (זמן תגובה קצר למשתמש הקצה); שנית, ביצועים מוכחים בספרות על משימות ראייה ממוחשבת מורכבות. גישה זו מאפשרת לנהל ניסויים בצורה יציבה ובטוחה מבלי לסכן את סביבת הפיתוח.

2.2 הגדרת הבעיה

הבעיה המרכזית בפרויקט היא חוסר היכולת של המשתמש הממוצע ולעיתים אפילו של מומחים לזהות תמונה מזויפת. המודלים הגנרטיביים החדשים מייצרים תמונות באיכות גבוהה, עם תאורה טבעית, טקסטורות עקביות ומבנים ויזואליים שנראים אותנטיים. זיהוי של דפוסים מלאכותיים (כמו רעשים, סימני עיבוד, ומאפיינים לא טבעיים) דורש ניתוח חישובי מתקדם שאינו נגיש לאדם רגיל.

בנוסף, שיטות זיוף חדשות מופיעות בקצב מהיר, ולכן כל מערכת לזיהוי צריכה להיות:

- עמידה לשינויים במודלים הגנרטיביים
- גמישה
- מבוססת על מספר שיטות ולא על פי שיטה אחת בלבד
- יעילה גם על תמונות מהשטח ולא רק על דאטה מלאכותי

לכן הפרויקט שלנו שואף לגבש פתרון אחד משולב שיכול לספק זיהוי אמין ואפקטיבי.

2.3 מטרות ויעדים

מטרת העל

פיתוח מערכת חכמה לזיהוי תמונות מזויפות (Deepfake) באמצעות שילוב של מספר שיטות ניתוח ובינה מלאכותית, תוך יצירת ממשק אינטואיטיבי של משתמשי הקצה.

יעדים מרכזיים

1. חקירה והבנה של טכנולוגיות הזיוף הקיימות - מודלי *GAN*, *Diffusion* ושיטות עיבוד תמונה.
2. בחינת שיטות קיימות לזיהוי זיופים ולנתח את ביצועיהן בעולם האמיתי.
3. בנייה והכשרה של מודל היברידי לזיהוי Deepfakes המשלב מספר גישות משלימות:
 - Frequency Analysis - ניתוח בתחום התדר באמצעות DCT (Discrete Cosine Transform)
 - Convolutional Traces - חילוץ עקבות קונבולוציה באמצעות אלגוריתם EM
 - SRM Filters - פילטרים עשירים מרחביים לזיהוי מניפולציות
 - ארכיטקטורות CNN מתקדמות - שילוב מודלים כגון ResNet, EfficientNet, DenseNet ו-Vision Transformers
 - מודלים קלאסיים - Logistic Regression, Random Forest, XGBoost, SVM
4. דיוק ושיפור תוצאות המודלים הקיימים באמצעות:
 - כיוונון היפר-פרמטרים (hyperparameter tuning)
 - שילוב אנסמבל של מודלים
 - אופטימיזציה של ביצועים על דאטה מורכב ו"מהשטח"
 - ניתוח תקלות (error analysis) והתאמת המודל בהתאם
5. פיתוח ממשק משתמש אשר מאפשר העלאת תמונה ובדיקתה בזמן אמת.
6. הערכה של ביצועי המערכת על דאטה מגוון, כולל תמונות מורכבות שאינן חלק מסביבת האימון.
7. שיפור דיוק המודל לאורך הפרויקט והטמעת התובנות שעולות מהבדיקות.

8. ביצוע מחקר השוואתי (Cross-Database Evaluation) בין שלוש ארכיטקטורות - CNN-SRM, ViT-Light ו-EfficientNetB0 - על ארבעה מאגרי נתונים, במטרה לבחון יכולת הכללה ועמידות.
9. השגת Accuracy מעל 85% ו-AUC מעל 0.90 על Test Set מאוחד של מודל ה-Ensemble הסופי.
10. הרחבת מאגר CustomWar פי 5 והוספת 2CelebDF כמאגר פריימי וידאו לשיפור הכללה ומניעת Overfitting.

2.4 חלופות (Alternative Approaches)

בטרם פיתוח המערכת נבחנות מספר חלופות טכנולוגיות:

א. ניתוח תדרים (Frequency Domain Analysis)

זיהוי דפוסים מלאכותיים בתדרים גבוהים בתמונה, הנוצרים כתוצאה מחלק מתהליכי יצירת ה-GAN.

יתרונות:

- יעיל גם על תמונות שעברו דחיסה.
- מזהה חתימות שקשה לאדם לראות.

חסרונות:

- רגיש למודלים חדשים שיכולים לטשטש תדרים.

ב. איתור עקבות קונבולוציה (Convolutional Traces)

כל רשת GAN מותירה אחריה מעין טביעת אצבע זעירה המבוססת על מסננים קונבולוציוניים.

יתרונות:

- דיוק גבוה מאוד במחקרים.
- מסוגל לזהות איזה מודל יצר את התמונה.

חסרונות:

- דורש חישוב כבד ולמידה עמוקה של מאפיינים זעירים.

ג. מודלי CNN מתקדמים (ResNet, EfficientNet, DenseNet, Vision Transformers)

רשתות עמוקות שלומדות מאפיינים ויזואליים היררכיים - מקצוות פשוטים ועד לתבניות מורכבות.

יתרונות:

- יכולת למידה של מאפיינים מורכבים באופן אוטומטי מהדאטה

- ארכיטקטורות מוכחות עם ביצועים גבוהים במשימות ראייה ממוחשבת
- ניתן להעביר ידע (transfer learning) ממודלים מאומנים מראש
- מתאימים לשילוב עם טכניקות נוספות (frequency analysis, SRM filters)

חסרונות:

- רגישות לשינויים במודלים גנרטיביים - כאשר מופיעים מודלי GAN/Diffusion חדשים, הביצועים עלולים לרדת (הבעיה של generalization)
- דורשים כמות גדולה של דאטה מגוון לאימון
- עלולים ללמוד artifacts ספציפיים של דאטה מסוים במקום מאפיינים כלליים של זיוף
- overfitting לדאטה מלאכותי - לא תמיד מכלילים היטב לתמונות "מהשטח"

ד. שיטות Pairwise / Self-Consistency

בדיקת עקביות בין אזורים שונים בתמונה.

יתרונות:

- יעיל במיוחד בתמונות של פנים.
- מצטיין בזיהוי חוסר טבעיות בין חלקי התמונה.

חסרונות:

- קשה ליישום על כל סוגי התמונות.

מסקנה

הפתרון האידיאלי הוא שילוב של כמה שיטות ליצירת מודל חזק ועמיד - ולא הסתמכות על מנגנון בודד.

2.5 משתמשים עיקריים ובעלי עניין (Stakeholders)

פרויקט זה העוסק בזיהוי תמונות מזויפות באמצעות למידה עמוקה וניתוח פורנזי חזותי רלוונטי למגוון רחב של משתמשים, חוקרים וארגונים. בעלי העניין עשויים להשתמש במערכת לצרכים ביטחוניים, מחקריים, תקשורתיים או פרטיים וכל אחד מהם זקוק ליכולת זיהוי אמينة, מהירה וידידותית שתוכל להתריע על תוכן שעבר מניפולציה.

להלן פירוט מורחב של בעלי העניין המרכזיים והצרכים הייחודיים שלהם:

1. גופי חדשות ותקשורת

עורכים, כתבים וגורמי תקשורת מתמודדים עם כמויות עצומות של תמונות המגיעות ממקורות לא מאומנים, רשתות חברתיות או אפליקציות מסרים. טעויות בזיהוי עלולות ליצור דיסאינפורמציה, לפגוע באמינות המערכת ולהוביל להטעיית הציבור.

הצרכים שלהם:

- אימות מהיר של אותנטיות התמונות המתקבלות מהשטח.
- מניעת פרסום תמונות מזויפות שעלולות לגרום לפאניקה, לשיימינג או לנזק תדמיתי.
- כלי בדיקה פשוט למפעיל, שאינו דורש ידע טכני עמוק.

כיצד המערכת משרתת אותם:

המערכת מאפשרת בדיקה מיידית של תמונה חשודה והצגת ציון אמינות ברור.

2. יחידות סייבר, מודיעין וחקירות ביטחוניות

גורמי ביטחון העוסקים באיתור קמפיינים של דיסאינפורמציה, זיהוי תוכן עוין והערכת סיכונים מבוססי מדיה. תמונות מזויפות משמשות בשנים האחרונות למבצעי השפעה, זיופי ראיות, והטעיית גורמים מבצעיים.

הצרכים שלהם:

- יכולת זיהוי מדויקת של תמונות שזויפו ע"י GAN או על ידי מניפולציות אחרות.
- תמיכה בניתוח אצווה של מאות תמונות במסגרת חקירה.
- תיעוד מלא של הבדיקה, כולל Metadata, לצרכים ראייטיים.

כיצד המערכת משרתת אותם:

המערכת מספקת יכולת בדיקה אוטומטית ותמיכה ביישומי חקירה שבהם נדרש תיעוד מלא ושחזור תוצאות.

3. חוקרי פורנזיקה דיגיטלית

חוקרים וחוקרי מחשב נדרשים לזהות זיופים בתמונות לצורך משפטי, פלילי או מודיעיני. ניתוח פורנזי דורש כלים המסוגלים לזהות אנומליות בעיבוד, רעשים לא עקביים ושאריות יצירה מלאכותית.

הצרכים שלהם:

- בדיקה מדויקת של ארטיפקטים עדינים בתמונה.
- כלי שמאפשר הבנה מעמיקה ולא רק תשובה בינארית.
- יכולת תיעוד וייצוא נתונים לקבצי חקירה.

כיצד המערכת משרתת אותם:

המערכת מספקת ניתוח מתקדם שמסביר למה התמונה חשודה, ולא רק אם היא מזויפת. הדבר מתאים לדרישות פורנזיות ומתועד כנדרש.

4. מוסדות אקדמיים וקהילת המחקר

חוקרים בתחומי Computer Vision, ביטחון מידע ו־Machine Learning משתמשים במערכות כאלה כדי לפתח מודלים חדשים, לבצע ניסויי השוואה ולהעשיר מאגרי ידע בתחום הזהוי.

הצרכים שלהם:

- גישה לאלגוריתמים פתוחים או ניתנים להרחבה.
- ממשק המאפשר בדיקות חוזרות (Reproducibility).
- כלים לניתוח ביצועים ולמידת מודלים על דאטה חדש.
- אפשרות לשלב את המערכת כחלק מפרויקטי סטודנטים או ניסויים מחקרניים.

כיצד המערכת משרתת אותם:

המערכת יכולה לשמש כבסיס למחקר, מאפשרת אימות ביצועים, ניסוי מעמיק והתנסות עם מודלים מתקדמים לזיהוי זיופים.

5. הציבור הרחב

משתמשים פרטיים נתקלים יותר ויותר בתמונות מפוברקות ברשתות החברתיות ובאפליקציות מסרים. לעיתים מדובר בתמונות מזיקות, פוגעניות או מטעות.

הצרכים שלהם:

- ממשק פשוט וידידותי שאינו דורש הבנה טכנית.
- תשובה מהירה וברורה: האם התמונה אמיתית או מזויפת.
- יכולת לבדוק תמונות המתקבלות בוואטסאפ, פייסבוק, אינסטגרם ועוד.
- שמירה על פרטיות - ללא שמירת תמונות אשר עלולות להכיל מידע אישי.

כיצד המערכת משרתת אותם:

המערכת מאפשרת לכל אדם להעלות תמונה ולקבל תוצאה ברורה ומיידית, בלי צורך בידע מקצועי.

לסיכום

בעלי העניין בפרויקט זה מגיעים מעולמות שונים - תקשורת, ביטחון, מחקר וציבור פרטי אך כולם חולקים את אותו הצורך: פתרון אמין, מהיר ומובן המזהה תמונות מזויפות ומתריע על תוכן פוגעני או מטעה. התייחסות מדויקת לצרכים של כל קבוצה מאפשרת התאמה טובה יותר של הפתרון, תכנון נכון ותעדוף פיצ'רים בהתאם.

2.6. פיצ'רים, סיפורי משתמש ודרישות לפיתוח

פיצ'רים מרכזיים במערכת:

המערכת כוללת מספר יכולות מרכזיות שנגזרות מצרכי הפרסונות שהוגדרו. כל פיצ'ר נועד לתת מענה למשתמשים שונים החל ממשתמש קצה ללא ידע טכני ועד חוקרים מקצועיים בתחום ה-Deepfake והסייבר.

1. העלאת תמונה ובדיקת תקינות

יכולות:

- העלאת תמונות מהמחשב ומהנייד
- תמיכה בפורמטים JPG / PNG / JPEG
- זיהוי קבצים פגומים
- ולידציה של פורמט/גודל לצורכי אבטחה

פרסונות: משתמש קצה, עיתונאי, חוקר סייבר, חוקר אקדמי

2. מנגנון סיווג תמונה (Real/Fake)

יכולות:

- ניתוח מבוסס CNN או מודל היברידי
- זיהוי עקבות עיבוד (Artifacts)
- ניתוח מאפייני תדר Frequency Analysis
- החזרת הערכת מודל: Real / Fake + Confidence

פרסונות: חוקר סייבר, חוקר אקדמי, משתמש קצה

3. הצגת תוצאה ברורה למשתמש (Real/Fake + Confidence)

יכולות:

- הצגת Real / Fake
- הצגת רמת ודאות באחוזים
- הסבר קצר ולא טכני

פרסונות: משתמש קצה, עיתונאי

4. מפת אזורים חשודים (Heatmap)

יכולות:

- הצגת Heatmap של אזורים חשודים
- השוואה בין תמונה מקורית ל-Heatmap

פרסונות: חוקר סייבר, חוקר אקדמי

5. ממשק משתמש פשוט ויזואלי (User Interface)

יכולות:

- עיצוב נקי וברור
- זרימת עבודה: העלאה -> ניתוח -> תוצאה
- התאמה למובייל

פרסונות: כולם

6. סריקת אבטחה וניתוח פורנזי דיגיטלי (Metadata & VirusTotal)

יכולות:

- סריקת קבצים מול VirusTotal וחסידת קבצים זדוניים בזמן אמת.
- חילוץ והצגת מטא-דאטה (EXIF) של התמונה (סוג מצלמה, חותמת זמן, רזולוציה, מיקום).
- הצגת אינדיקציה במקרה של חוסר במטא-דאטה (EXIF Stripping).

פרסונות: חוקר סייבר, עיתונאי, משתמש קצה.

סיפורי משתמש:

פיצ'ר	סוג משתמש	עדיפות	סיפור משתמש	דרישות לפיתוח
העלאת תמונה ובדיקת תקינות	משתמש קצה / עיתונאי / חוקר סייבר	גבוהה	אני כמשתמש רוצה להעלות תמונה בקלות כדי לבדוק האם היא אמיתית או מזויפת	- בניית קומפוננט העלאה ב-React - בדיקת תקינות בסיסית בצד לקוח (סיומת/גודל) - בדיקות אבטחה: איומת סיומת, הגבלת גודל - אינטגרציה עם VirusTotal
מנגנון סיווג תמונה (Real/Fake)	חוקר סייבר / חוקר אקדמי / משתמש קצה	גבוהה	אני כמשתמש רוצה שהמערכת תנתח את התמונה כדי לדעת אם היא אמיתית או מזויפת (Real/Fake)	- טעינת weights של המודל ב-Flask - ביצוע Processing: שינוי גודל, נימול, SRM/Frequency - הרצת המודל על CPU/GPU לפי זמינות - החזרת תוצאה בפורמט JSON כולל + Real/Fake + אחוזי רמת וודאות
הצגת תוצאה ברורה למשתמש	משתמש קצה / עיתונאי	גבוהה	אני כמשתמש רוצה לראות תוצאה ברורה כדי להבין מיד האם התמונה אמיתית או מזויפת	- פיתוח מסך תוצאות ב-React - הצגת תוצאה בולטת: Real/Fake בצבעי אינדיקציה - הצגת אחוז וודאות - הצגת הסבר קצר ולא טכני
מפת אזורים חשודים (Heatmap)	חוקר סייבר / חוקר אקדמי	בינונית	אני כחוקר רוצה לראות מפה של אזורים חשודים בתמונה כדי להבין מה גרם לסיווג	- יצירת Heatmap ב-Backend - פיתוח תצוגה להשוואה : מקור מול Heatmap
ממשק פשוט ויזואלי למשתמש	כל המשתמשים	גבוהה	אני כמשתמש רוצה ממשק ברור ונוח כדי שאוכל להפעיל את המערכת בקלות גם ללא ידע טכני	- עיצוב מסמכים ב-React לזרימה : העלאה -> עיבוד -> תוצאה - התאמה מלאה למובייל - הצגת שגיאות יזודיות למשתמש - אנימציות טעינה בזמן עיבוד התמונה לצורך חייווי למשתמש בזמן תהליך הטעינה
ניתוח מטא-דאטה	חוקר סייבר / עיתונאי	גבוהה	אני כמשתמש מקצועי רוצה לצפות בנתוני המטא-דאטה של התמונה (EXIF), כדי לקבל רמזים פורכניים נוספים לגבי מקור	- חילוץ EXIF בפייתון - העברת הנתונים ב-JSON - בניית רכיב תצוגה ב-React

	התמונה והאם עברה עריכה או דחיסה			
• אינטגרציה ל-API של VT • חישוב HASH לקובץ • חסימת הבקשה להעלאת תמונה • הצגת שגיאה למשתמש במקרה של זיהוי איום	אני כמפתח/מנהל המערכת רוצה שכל קובץ ייסרק ב-VirusTotal לפני עיבוד כדי למנוע החדרת קוד זדוני וקריסת שרת ה-Flask	קריטית	ס מערכת/אדמין	

משימות ודרישות בנוגע לפיתוח המודל:

משימה	דרישות לפיתוח
איסוף וארגון של תמונות אמיתיות ומזויפות	1. בחירת מאגרי נתונים מתאימים. 2. סינון תמונות בעייתיות (רזולוציה נמוכה, קבצים פגומים, כפילויות). 3. תיוג ברור של כל תמונה כ-Real או Fake. 4. חלוקה ל-Train / Validation / Test ממקורות שונים.
עיבוד מקדים לתמונות ויצירת ייצוגי תדר (Preprocessing + Frequency Maps)	1. הגדרת גודל תמונה אחיד וביצוע נרמול. 2. הפקת ייצוגי תדר באמצעות FFT או SRM ושמירת המפות הנגזרות. 3. בניית Pipeline אוטומטי ב-Colab שמכין את כל התמונות למודל. 4. בדיקה ידנית על דגימה קטנה לוודא תקינות תהליך העיבוד.
בחירה ובניית ארכיטקטורת המודל	1. בחירת רשת בסיס. 2. התאמת שכבות הסיום למשימת סיווג בינארי Real/Fake. 3. קביעת פונקציית הפסד ומדדי הערכה. 4. תיעוד הנימוקים בהתאם לסקר הספרות ולניסויים שבוצעו.
אימון המודל וכיוונון היפר-פרמטרים	1. הרצת ניסויים שונים: מודל בסיס, מודל עם תדירים, מודל עם Augmentation 2. שימוש ב-Early Stopping למניעת Overfitting. 3. שימוש ב-Learning Rate Scheduler לשיפור יציבות האימון. 4. השוואת ביצועים ובחירת המודל המתאים ביותר לפי Validation Set.
בדיקת הכללה ועמידות של המודל	1. בדיקה על סט חיצוני שלא השתתף באימון 2. ביצוע סימולציות של דחיסה והורדת איכות לדמות רשתות חברתיות 3. השוואת ביצועים לפני ואחרי דחיסה וניתוח מקודות כשל 4. תיעוד מגבלות המודל והצעות לשיפור
ייצוא המודל ושילובו בשרת Flask	1. שמירת המודל בפורמט מתאים כולל גרסה ותאריך 2. כתיבת פונקציית טעינה ו-predict בצד ה-Backend 3. מדידת זמן ריצה ממוצע ושיפורו לפי צרכי המערכת 4. הוספת לוגים עבור בדיקות ומעקב
בדיקות מערכת מקצה לקצה	1. בדיקה שהשרשרת עובדת: העלאת תמונה -> עיבוד מקדים -> מודל -> תוצאה 2. הרצה על מגוון סוגי תמונות (אמיתיות, מזויפות, דחוסות, איכות נמוכה). 3. טיפול בשגיאות וחריגות כך שהמערכת לא תקרוס

4. תיעוד תוצאות הבדיקות בהתאם למדדי ההצלחה שהוגדרו בפרויקט	
--	--

2.7 מצב קיים וחלופות הקיימות בשוק -

מערכת	סוג	קוד פתוח	שקיפות אלגוריתמית	שיטות ML בשימוש	עלות	יתרונות	חסרונות
Sensity AI	מסחרי	סגור	נמוכה	רשתות CNN, ניתוח וידאו, Multi-modal	בתשלום (רישיון מסחרי/ארגוני)	מערכת יציבה, תיעוד מקיף, API, כוללת מודיעין סייבר	בנויה בעיקר לווידאו, יקרה מאוד, "קופסא שחורה", דורשת אישור ידני למשתמש ע"י המנהל טרם השימוש באתר
BioID	מסחרי	סגור	גבוהה חלקית	Face recognition + Liveness detection	בתשלום (רישיון מסחרי)	יציב ואמין מאוד לאימות זהות ביומטרי	מתמקד בבדיקת "חיות" ולא בזיהוי מדיה סינטטית, אינו כלי Web נגיש להעלאת קבצים
Hive AI	מסחרי	סגור	נמוכה	Deep Learning models for GenAI Detection	בתשלום (לפי נפח שימוש ב-API)	דיוק גבוה מאוד בזיהוי תמונות שנוצרו ע"י כלי AI, תומך בטקסט/אודיו	מיועד למפתחים/חברות, למשתמש הפרטי יש גישה מוגבלת מאוד, ללא הסבר ויזואלי (Heatmap) למשתמש הקצה
Deepware Scanner	מסחרי / קהילתי	פתוח חלקית	בינונית	Ensemble of Open Source Models	חינם (לשימוש באתר)	ממשק פשוט מאוד (Upload & Check), משלב מספר מודלים לבדיקה רחבה	מסתמך על מודלים ישנים יחסית, נכשל בזיהוי תמונות גנרטיביות, ביצועים לא אחידים
AI or Not	מסחרי	סגור	נמוכה	Specialized Deep Learning for GenAI Artifacts	חינם באתר, תשלום ב-API	פתוח ונגיש לציבור הרחב, ממשק WEB פשוט ומהיר, מתמקד ספציפית בזיהוי תמונות גנרטיביות	"קופסה שחורה" - נותן רק תוצאה "AI" או "Human" בלי להסביר למה וכלי לסמן אזורים חשודים, שיעור טעויות גבוה באמנות דיגיטלית

לפני פיתוח המערכת נדרש לבחון את הפתרונות הקיימים כיום בשוק לזיהוי תמונות ו־Deepfake. קיימים מספר כלים פופולריים חלקם מסחריים וחלקם לא מחקריים, אך לכל אחד יש מגבלות מהותיות המצדיקות פיתוח מערכת משופרת.

על בסיס ניתוח החלופות הקיימות עולה כי אף אחד מהפתרונות אינו נותן מענה מלא לשילוב הדרישות של דיוק, עמידות, שקיפות ושימושיות למשתמש הקצה באופן מיידי. המערכת המוצעת שואפת לענות על פער זה באמצעות מספר מאפיינים מרכזיים:

- התמקדות בתמונות סטילס ולא רק בווידיאו, ובכך נותנת מענה לתרחישים יומיומיים נפוצים (רשתות חברתיות, אפליקציות מסרים, אתרי חדשות).
- שילוב היברידי של מספר שיטות פורנזיות - ניתוח תדרים (Frequency), עקבות קונבולוציה ורעש (CTs/SRM) ומודל CNN - במקום הסתמכות על גישה בודדת.
- עמידות טובה יותר לדחיסה ולעיבוד רשתות חברתיות- באמצעות אימון ובדיקה גם על תמונות דחוסות ומדומות "מהשטח" ולא רק על דאטה אקדמי נקי.
- שקיפות גבוהה בהחלטת המודל - הצגת Heatmap ואזורים חשודים, לצד הסבר טקסטואלי קצר, במקום "קופסה שחורה" שמחזירה רק Real/Fake.
- ממשק משתמש פשוט ונגיש המותאם גם לעיתונאים, חוקרי סייבר ומשתמשים ללא רקע טכני, עם תוצאה ברורה (Real/Fake + אחוז ודאות).
- כיוון מחקרי - יישומי - חלקים מהמערכת והמודל מיועדים להיות ניתנים להרחבה ולשימוש כחלק מניסויים אקדמיים, בניגוד לכלים מסחריים סגורים.

לסיכום, תרומת הפרויקט אינה במודל זיהוי נוסף בלבד, אלא בבניית מערכת שלמה שמחברת בין יכולות פורנזיות מתקדמות לבין חוויית שימוש ידידותית, תוך דגש על עמידות ושקיפות - שילוב שאינו מתקבל במלואו באף אחת מן החלופות שנבחנו.

2.8 חוקים ואילוצים

בפיתוח מערכת לזיהוי Deepfake קיימות מספר מגבלות ודרישות משפטיות, טכנולוגיות ואתיות שיש לעמוד בהן:

2.8.1 שמירה על פרטיות המשתמש

- המערכת אינה שומרת תמונות באופן קבוע ללא אישור מפורש מהמשתמש.
- כל תמונה שעולה למערכת תיבדק ותימחק אוטומטית עם סיום התהליך, למעט מקרים בהם המשתמש מסכים לשמירה לצורכי מחקר או שיפור ביצועים.

2.8.2 שמירת פרטי שימוש מינימליים

על מנת להגן על המערכת ועל צוות הפיתוח מפני שימוש לרעה המערכת שומרת פרטים טכניים מינימליים בלבד, הכוללים:

- כתובת IP
- זמן הבדיקה
- מזהה בדיקה טכני
- סוג הדפדפן/מכשיר (User-Agent)

שמירת נתונים זו נועדה ליצירת Traceability בסיסית המאפשרת לזהות ניסיונות שימוש זדוני או הפרת תנאי שימוש, ולהוכיח במידת הצורך כי צוות הפרויקט אינו אחראי להפקת התוכן שהועלה, אלא רק לניתוחו.

המידע אינו כולל פרטים אישיים, אינו משויך למזהה משתמש, והוא נשמר לפרק זמן מוגבל בהתאם למדיניות אבטחת המידע של המערכת.

2.8.3 עמידה ברגולציות AI

- המערכת פועלת בכפוף להוראות חוק הגנת הפרטיות, התשמ"א-1981 ולהנחיות הרשות להגנת הפרטיות בנושא שימוש במידע ביומטרי ובינה מלאכותית.
- הנחיות אלו קובעות כי אין לעבד מידע אישי ללא הסכמה מדעת וללא מטרות מוגדרות.¹
- אין להחזיק, להעביר או לעבד מידע אישי ללא מטרות מוגדרות והסכמה.

2.8.4 אבטחת מידע

- יש להגן על המערכת מפני העלאת קבצים זדוניים, ניסיונות הזרקת קוד או מניפולציה במערכת.
- השימוש בכלי צריך להיות בהתאם לכללי אתיקה, תוך מניעת פגיעה בפרטיות או שימוש לרעה ביכולות זיהוי.

2.8.5 אתיקה

- המערכת נועדה לספק הערכה טכנולוגית בלבד, ואינה מחליפה חוות דעת משפטית או קביעה פורסנית רשמית.
- במקרה שמשתמש מעלה תמונה שעברה עריכה במכוון (לדוגמה, יצירת פרופיל מזויף), האחריות על תוכן התמונה חלה על המשתמש בלבד.
- הנתונים המינימליים שנשמרים (IP, זמן בדיקה) מאפשרים להוכיח שהמערכת לא יצרה את התמונה ולא קשורה עצמונית לתוכן שהועלה.

2.8.6 אילוצי שימושים וביצועים

- **ממשק ידידותי ופשוט:**
המערכת צריכה להיות קלה להבנה ולשימוש, כך שגם משתמש קצה ללא ידע טכני יכול להעלות תמונה ולקבל תוצאה ללא צורך בהדרכה. מסכי האתר יעוצבו בצורה נקייה ואינטואיטיבית, עם מספר מינימלי של פעולות נדרשות מהמשתמש.

- **מהירות תגובה:**
המשתמשים מצפים לקבל תוצאה בזמן קצר ולכן זמן התגובה הרצוי הוא מספר שניות בודדות

¹ משרד החדשנות, המדע והטכנולוגיה, "עקרונות מדיניות, רגולציה ואתיקה בתחום הבינה המלאכותית". https://www.gov.il/he/pages/ai_privacy

מרגע העלאת התמונה. תהליך העיבוד (Preprocessing + הרצת המודל) יתוכנן כך שיהיה יעיל ולא יגרום לעיכובים משמעותיים.

- **למידת אופן השימוש:**

מאחר והמערכת מיועדת גם למשתמשים שאינם מומחי תוכנה, על הניסוחים בממשק להיות בשפה פשוטה וברורה, ללא עומס מונחים טכניים. כך ניתן לצמצם את זמן הלמידה ולהבטיח שהמשתמש יבין את משמעות התוצאה (Real/Fake + אחוזי ודאות) ללא צורך בהסברים חיצוניים.

2.9 צרכי משתמשים

כדי שהמערכת תהיה שימושית ונגישה, בבנייתה אנו נדרשים לענות על הצרכים הבאים:

- **ממשק פשוט וברור** - העלאת תמונה בלחיצה אחת
- **מהירות תגובה גבוהה** - חסם עליון של עד 5 דקות לעיבוד תמונה בודדת כדי לאפשר חווית משתמש חלקה.
- **דיוק גבוה ואמינות** - עמידה ביעד דיוק של מעל 95% על סט הבדיקה, תוך מזעור התראות שווא (False Positives).
- **הצגת אחוזי ודאות ולא רק תשובה בינארית**
- **תמיכה בתמונות איכות נמוכה או דחוסה**
- **שקיפות ופורבדיקה משלימה:** מענה לצורך של חוקרים באימות הקשרי (Contextual) של התמונה מעבר לתוכן הוויזואלי. שימוש במטא-דאטה מאפשר לזהות סתירות בזמנים או במיקומים גם אם המודל מתקשה לסווג את התמונה.

2.10 סיכונים

בפרויקט הוגדרו מספר סיכונים מרכזיים הקשורים למודל ה-AI, לאיכות הדאטה, לאמינות המערכת ולסביבת ההפעלה. הטבלה הבאה מציגה את עיקר הסיכונים יחד עם הערכת סבירות, חומרה ופעולות לצמצום הסיכון במסגרת הפרויקט.

תיאור הבעיה	סיכוי	סיווג חומרה	פתרון / התמודדות
מודלים גנרטיביים חדשים עוקפים את המערכת - מודל הזיהוי שאומן על Deepfakes "ישנים" לא מצליח לזהות תמונות שנוצרו בעזרת מודלי GAN/Diffusion מתקדמים יותר	בינוני	גבוהה	עדכון מתמשך של ה-Dataset עם דוגמאות ממודלים חדשים, הרצת ניסויי Generalization על סטים חיצוניים, ושמירת תהליך אימון מתמשך (Fine-tuning) תקופתי של המודל.
דיוק נמוך על דאטה אמיתי ("מהשטח") - המערכת מציגה ביצועים טובים על דאטה האקדמי, אבל יורדת משמעותית כשבדוקים תמונות מהעולם האמיתי (רשתות חברתיות, דחיסה, רעש).	גבוהה	גבוהה	שילוב בתהליך האימון תמונות דחוסות ושונות באיכות, ביצוע סימולציות Post-processing (דחיסה, שינוי גודל, רעש) כבר בשלב ה-Preprocessing, והערכת ביצועים נפרדת על Test Set "מהשטח".
בעיית Overfitting למאגר נתונים מסוים - המודל "זוכר" את סט האימון ולא מצליח להתאים את עצמו לסטים חדשים.	בינוני	גבוהה	שימוש ב-Regularization, Early Stopping, הפרדה קפדנית בין Train / Validation / Test ממקורות שונים ותיעוד ניסויים כדי לבחור מודל מאוזן ולא רק הכי מדויק על ה-Train.
הטיות בדאטה ((Bias - ייצוג יתר של סוגי תמונות/פרצופים מסוימים עלול לגרום למודל להיות פחות מדויק עבור אוכלוסיות אחרות.	בינוני	גבוהה	דגש על בחירת Datasets מגוונים, בדיקת התפלגויות (מין, גיל, טייפ צילום), הוספת סטים מאזנים במידת האפשר, ותיעוד מגבלות המודל מבחינת הטיות.
עומס נתונים וביצועים - תמונות כבדות, בקשות רבות בו-זמנית, או שימוש ב-GPU מוגבל עלולים להוביל לזמני תגובה ארוכים ולחוויה לא טובה למשתמש.	בינוני	גבוהה	הגבלת גודל קובץ, Preprocessing יעיל (שינוי גודל אחיד), מדידת זמן ריצה כבר בשלב המחקר, אפשרות לתור בקשות (Queue) במידת הצורך ותיעוד אופטימיזציה של המודל למהירות ולא רק לדיוק.
פגיעה באמון המשתמש - המערכת מחזירה לעיתים תוצאות שגויות או לא ברורות, והמשתמשים עלולים לא לסמוך על הפלט (במיוחד עיתונאים וחוקרי סייבר).	בינוני	גבוהה	הצגת Confidence ברור, מתן הסבר קצר (למשל: "נמצא סימני עיבוד בתדרים גבוהים"), הצגת Heatmap במידת האפשר, וציון מפורש שהמערכת היא כלי מסייע ולא תחליף לחוות דעת פורנזית

רשמית.			
מחיקת תמונות לאחר הבדיקה (אלא אם המשתמש הסכים לשמירה למחקר), שמירת לוגים טכניים בלבד (IP, זמן בדיקה, מזהה בקשה), אימות סוג וגודל קובץ, אינטגרציה עם VirusTotal, עבודה ב-HTTPS ו-Rate Limiting בסיסי.	קריטית	נמוך - בינוני	סכנת נזק
הוספת דיסקליימר ברור בממשק ובדוחות: המערכת מספקת הערכה טכנולוגית בלבד, אינה מחליפה חוות דעת משפטית/פורבזית; המלצה לצרף את התוצאה כחוות דעת משלימה בלבד.	גבוהה	נמוך - בינוני	שימוש לא אתי בתוצאה - משתמש עשוי לפרש את החלטת המערכת כ"ראיה חד משמעית" ולהציג אותה בהקשר משפטי/תקשורתי מבלי להבין את מגבלותיה.
פירוק משימות בג'ירה, חלוקה ברורה בין שלבי מחקר לפיתוח, אבני דרך מוגדרות (MVP עובד עם מודל בסיסי, ואז שיפור הדרגתי), וסנכרון קבוע בין חברי הצוות.	בינונית	בינוני	סיכון תהליכי/לוח זמנים - שילוב בין מחקר מודלים, פיתוח Frontend/Backend וכתיבת הדוח עלול לעכב עמידה בלוחות הזמנים.

2.11. ארגון

צוות הפיתוח

צוות הפיתוח של פרויקט זה כולל שלושה חברי צוות בעלי התמחות משלימה בתחומי הסייבר, למידת המכונה ופיתוח יישומים. שילוב הידע המחקרי, התשתיתי והאפליקטיבי מאפשר בניית מערכת יציבה, אמינה ואיכותית לזיהוי תמונות מזויפות (Deepfake).

• עדן כהן - פיתוח Frontend, חוויית משתמש ואבטחת מידע

לעדן ניסיון של כ-5 שנים בתחום הסייבר, כולל הבנה מעמיקה של אבטחת מידע, זיהוי איומים והקשחת מערכות. שילוב של ידע מקצועי בתקשורת, רשתות, זיהוי קבצים דו-כיווניים ונהלי אבטחה מאפשר לה לתכנן ממשק משתמש אמין ויציב שאינו רק נוח - אלא גם בטוח לשימוש. עדן אחראית על פיתוח ממשק ה-React, עיצוב המסכים, בניית זרימת העבודה ויישום בדיקות תקינות ואבטחת קובץ בצד הלקוח, כולל אינטגרציה עם VirusTotal למניעת העלאת קבצים דו-כיווניים. שילוב הידע בסייבר עם הבנה עיצובית מעניק למערכת ממשק איכותי ומאובטח לכלל המשתמשים.

• נועם דהן - מחקר נתונים, למידת מכונה ופיתוח מודלי AI

לנועם ניסיון מעשי בחקר נתונים, למידת מכונה ופיתוח מודלים עמוקים, לצד השתתפות בפרויקטים אקדמאיים בתחום עיבוד תמונה ופיתוח תנועה. נועם מתמקדת בפיתוח הלוגיקה האלגוריתמית של המערכת, בבנייה של Pipelines לעיבוד תמונה ויצירת ייצוגי תדר (SRM / Frequency Maps), בחילוף מאפיינים מורכבים ואימון מודלים היברידיים

לזיהוי זיופים וזיואליים.

השילוב בין גישה מחקרית, יכולת ניתוח מתקדמת ושליטה בכלים חישוביים מהווה נדבך מרכזי בבניית המודל ובשיפור יכולות ההכללה והעמידות של מערכת הזיהוי.

● גל טייב – פיתוח Backend, למידת מכונה ויישומי אבטחת מידע

לגל ידע וניסיון הן בתחום הסייבר והן בתחום למידת המכונה, תוך השתתפות בפרויקטים אקדמיים ומעשיים בנושאי Data Analysis, מודלי ML ואבטחת תוכנה. במסגרת הפרויקט גל אחראי על פיתוח רכיבי ה-Backend ב-Flask, הטמעת המודל המאומן בתוך השרת, בניית תהליכי Preprocessing בצד השרת, ניהול לוגים, תקשורת API עם ה-Frontend ויישום מנגנוני אבטחה בסיסיים (בדיקות קובץ, טיפול בחריגות, בקורות שרת). שילוב הידע שלו בעיבוד נתונים, למידת מכונה ואבטחת מידע מאפשר לו ליצור שכבת Backend יציבה, יעילה ומדויקת שתומכת בכל תהליך הניתוח במערכת.

גורמים מעורבים

ד"ר אירינה רבייב מנחת הפרויקט בתחום הראייה הממוחשבת ועיבוד התמונה. בעלת ניסיון רב בהוראה ובהנחיית פרויקטים מחקריים, תוך התמחות בשיטות לניתוח תמונה, בניית מודלים מתמטיים וביישום טכניקות פורנזיות. תרומתה לפרויקט מתבטאת בהכוונה מחקרית, בחינת פתרונות מודל מבוססי למידת מכונה, ליווי בתהליכי ניסוי והערכה, והתאמת שיטות עבודה תקפות ומדויקות.

ד"ר אלונה קוצני מנחת הפרויקט בתחום הסייבר ואבטחת המידע. היא בעלת ידע רחב בזיהוי איומים, הגנה על מערכות, ניתוח סיכונים והטמעת בקורות אבטחה בעולמות תוכנה והן בעולמות הקריפטוגרפיה. תרומתה לפרויקט כוללת הנחיה מקצועית בבניית מנגנוני הגנה, בדיקות תקינות לקבצים, עבודה מסודרת לפי עקרונות Best Practice, והבטחת פיתוח מערכת יציבה ומאובטחת.

תהליך העבודה

תהליך העבודה בפרויקט יתבצע באופן הדרגתי ומאורגן, תוך חלוקה לשלבים ברורים המשלבים מחקר, פיתוח אפליקטיבי ובדיקות. כל שלב יתבסס על תוצרים של השלב הקודם, ויאפשר התקדמות עקבית עד להשלמת מערכת מלאה לזיהוי תמונות מזויפות.

שלב א' - חקר, לימוד ואיסוף מידע

בשלב הראשון תבוצע סקירת ספרות מעמיקה בנושאי עיבוד תמונה, מודלים גנרטיביים (GAN \ Diffusion) ושיטות קיימות לזיהוי Deepfake. יתבצע ניתוח של פתרונות קיימים בשוק, זיהוי מגבלותיהם והבנת הפערים הטכנולוגיים שהמערכת המוצעת נדרשת לפתור. בהמשך, יוגדרו צרכי המשתמשים, ינותחו תרחישים וייבנה מסמך ייחוס ראשוני הכולל מטרות, יעדים ודרישות מערכת.

שלב ב' - אפיון מפורט והגדרת דרישות המערכת

בשלב זה יתבצע אפיון מלא של המערכת, הכולל:

- דרישות פונקציונליות ולא-פונקציונליות
- תרשימי UML
- הגדרת ארכיטקטורת Frontend-Backend-Model
- אפיון חוויית משתמש ועיצוב הממשק
- חלוקת משימות בין חברי הצוות בג'ירה

האפיון ישמש בסיס תכנוני מוצק לפיתוח ומחקר בהמשך.

שלב ג' - בניית Dataset ועיבוד מקדים ((Preprocessing

בשלב זה ירדו מאגרי תמונות הכוללים דוגמאות אמיתיות ומזויפות. יופעל Pipeline של עיבוד מקדים שיכלול:

- ניקוי המידע וסינון תמונות פגומות
- שינוי גודל ונרמול
- הפקת ייצוגי תדר (FFT / Frequency Maps)
- הפקת מסנני SRM
- בניית מבנה נתונים תקני לחלוקה ל-Train / Validation / Test

התהליך יתועד ובדיקות ראשוניות יבוצעו לאימות תקינות המידע.

שלב ד' - מחקר מודלים ואימון (Model Training)

במהלך שלב זה ייבחנו מספר ארכיטקטורות לזיהוי זיופים, כגון:

- מודלי CNN מסורתיים
- מודלים מתקדמים מסוג ResNet/VGG
- מודל היברידי המשלב מידע מרחבי ותדרי

יופעלו ניסויי אימון שונים, כיוון היפר-פרמטרים, בדיקות Generalization ובדיקות Robustness לדחיסה והורדת איכות.

בתום השלב ייבחר המודל המתאים ביותר לשילוב במערכת.

שלב ה' - פיתוח Backend

בשלב זה יפותח שרת Flask הכולל:

- API לקבלת תמונה וניתוח קלט
- בדיקות אבטחה בסיסיות (סיומת, גודל, סריקה ב-VirusTotal)
- יישום Preprocessing בצד השרת
- טעינת המודל והפקת תוצאה Real/Fake
- ניהול לוגים ב-SQLite
- החזרת נתונים ל-Frontend בפורמט JSON

ה-Backend ייבדק באמצעות כלים כמו Postman.

שלב ו' - פיתוח Frontend

בשלב זה יפותח ממשק המשתמש ב-React, ויכלול:

- העלאת תמונה
- הצגת תוצאות (Real/Fake + רמת ודאות)
- הצגת Heatmap בשלב מתקדם
- עיצוב ואופטימיזציה לחוויית משתמש
- טיפול בשגיאות והודעות מערכת

הממשק ייבנה תוך הקפדה על פשטות, בהירות ונגישות.

שלב ז' - אינטגרציה

בשלב זה יחוברו ה-Frontend וה-Backend למערכת אחת אחודה, יבוצעו:

- בדיקות מסלול מלא (End-to-End)
- בדיקות תקינות של תהליך העלאה -> עיבוד -> תוצאה
- בדיקות איכות המידה המוחזרת מהמודל
- שיפור זמני תגובה והתאמת עומסים

שלב ח' - בדיקות מערכת ושיפור ביצועים

המערכת תיבדק על מגוון תמונות אמיתיות ומזויפות, כולל תמונות שעברו:

- דחיסה
- שינוי גודל
- רעש
- עיבוד נוסף

יוגדרו מדדי הצלחה ולפיהם תיבחן המערכת. בהתאם לתוצאות יתבצעו שיפורים במודל, בתצוגה ובביצועים.

שלב ט' - הכנה להצגת הפרויקט

בשלב הסופי:

- כתיבת הדו"ח המלא
- יצירת מצגת להצגת הפרויקט
- הפקת סרטון דמו
- תיעוד סופי של המערכת, ה-Dataset והמודלים

זהו שלב המסכם את העבודה ומציג את המערכת כמוצר שלם.

3. עיצוב ודרישות

3.1 הגדרת פרסונות (Personas)

הפרויקט פונה למגוון משתמשים בעלי צרכים שונים. נגדיר פרסונות לצורך הבנה והעמקה של מי עתיד להשתמש במערכת ומהם השימושים הצפויים.

3.1.1 משתמש קצה - אדם ללא ידע טכני

- חצה לבדוק האם תמונה שקיבל ברשת היא אמיתית או מזויפת.
- מצפה לממשק פשוט וברור, ללא הסברים מורכבים.
- דורש זמן תגובה מהיר ותוצאה ברורה: Real/Fake - אחוזי ודאות.

3.1.2 חוקר אבטחת מידע/סייבר

- מעוניין לבצע בדיקה מדויקת של תמונות חשודות.
- צריך גישה למידע מעט יותר טכני (למשל מאפייני תדר, עקבות עיבוד וכו').
- מצפה למערכת אמינה עם רמת דיוק גבוהה.

3.1.3 עיתונאי/עורך תוכן

- נדרש לאמת תמונות לפני פרסום כתבה.
- צריך דרך מהירה להעלות תמונה ולקבל אימות.
- מעוניין בכלי שיעזור במניעת פרסום מידע שגוי והפצתו.

3.1.4 סטודנט/חוקר אקדמי

- משתמש במערכת לצורכי מחקר בנושא Deepfake.
- מעוניין בניתוחים גרפיים ובאפשרות לבחון דגמי מודלים שונים.

3.2 דרישות פונקציונליות (Functional Requirements)

3.2.1 העלאת תמונה

- המשתמש יוכל להעלות תמונה מהמחשב או מהנייד.
- המערכת תתמוך בפורמטים נפוצים: JPG, PNG, JPEG.

- המערכת תציג שגיאה במקרה של פורמט שאינו נתמך או תמונה פגומה.

3.2.2 ביצוע ניתוח לתמונה

- המערכת תשלח את התמונה למודל לזיהוי Deepfake.
- המודל יבצע ניתוח הכולל:
 - אנליזת תדרים
 - בדיקת עקבות עיבוד
 - ניתוח תבניות CNN
 - מודל משולב (Hybrid Model)

3.2.3 סריקת אבטחה מקדימה

- המערכת תחשב גיבוב (Hash) מסוג SHA-256 לכל קובץ שמועלה.
- המערכת תשלח את הגיבוב לבדיקה מול ה-API של VirusTotal.
- במקרה שהקובץ מזוהה כזדוני (Malicious), המערכת תעצור את תהליך העיבוד, תמחק את הקובץ ותציג שגיאה ברורה למשתמש.

3.2.4 חילוץ נתונים פורנזיים (Metadata)

- המערכת תחלץ נתוני EXIF המוטמעים בקובץ התמונה (כגון חותמת זמן, נתוני מצלמה, תוכנת עריכה).
- המערכת תציג את הנתונים למשתמש בחלונית ייעודית בממשק.
- במקרה שהקובץ עבר דחיסה (למשל נשלח בוואטסאפ) והמטא-דאטה הוסר, המערכת תטפל בכך בצורה תקינה (Graceful Degradation) ולא תקרוס אלא פשוט לא תציג נתונים.

3.2.5 הצגת תוצאות למשתמש

- המערכת תציג האם התמונה Real/Fake.
- תוצג רמת ודאות באחוזים.
- תוצג תובנה בסיסית של המערכת לדוג': "נמצאו סימני עיבוד לא טבעיים / עקביות נמוכה באזור הפנים".

3.2.6 ניהול לוגים (לצורכי Backend)

- כל בדיקת תמונה תישמר במערכת ותכלול:
 - מזהה בדיקה ייחודי
 - זמן הבדיקה
 - תוצאת הבדיקה (Real/Fake)
 - סטטוס הבדיקה (הצליחה/נכשלה)
 - מידע טכני על התמונה (סוג קובץ, גודל, רזולוציה)
 - סוג המודל שנבחר וגרסתו
 - רמת ביטחון של המודל (כמו אחוזי וודאות)

- זמני ריצה
- קישור או מזהה לקובץ התמונה שנשמרת בשרת

3.3 דרישות לא-פונקציונליות (Non-Functional Requirements)

3.3.1 ביצועים (Performance)

- **זמן תגובה רצוי:** עד 5 דקות לעיבוד תמונה.
- **עיבוד מקבילי:** המערכת תאפשר הרצת מספר בדיקות בו-זמנית על ידי משתמשים שונים.
הערה: כמות הבדיקות המקבילות המקסימלית תיקבע בהתאם למפרט השרת (Hardware Dependent) שיוקצה בשלב ההטמעה, מתוך מטרה לנצל באופן אופטימלי את משאבי ה-CPU/GPU הקיימים.

3.3.2 שימושיות (Usability)

- ממשק נוח, נקי וברור למשתמש.
- תוצאות מוצגות בשפה פשוטה להבנה.
- התאמה למובייל לצורך נוחות.

3.3.3 אבטחה (Security)

- תמונות לא ישמרו בשרת ללא אישור המשתמש.
- כל פעולה רצה על ערוץ מאובטח HTTPS.
- המערכת תטפל בהגנות מפני:
 - העלאת קבצים זדוניים
 - הצפות על המערכת

3.3.4 אמינות (Reliability)

- המערכת צריכה להיות זמינה מעל 95%.
- טיפול בשגיאות בצורה ברורה וידידותית עם חיווי למשתמש.

3.3.5 יכולת הרחבה (Scalability)

- המערכת תוכל בעתיד לעבוד עם מספר מודלים במקביל.
- תמיכה במאגרי תמונות גדולים יותר.
- הפרדה ברורה בין שכבות - נבנה את המערכת באמצעות ארכיטקטורה מודולרית כך שניתן יהיה להחליף או להוסיף מודלים בלי לפגוע בשאר המערכת.
- אפשרות לפריסה בענן - המערכת תוכל לרוץ על תשתית ענן כדי לאפשר הרחבה קלה בעת עלייה בכמות המשתמשים או התמונות.
- תמיכה בהרצת Batch - אפשרות לעיבוד קבוצת תמונות בבת אחת ולא רק תמונה בודדת, לצורכי מחקר/בדיקה רחבה.

- ניהול משאבים חכם - התאמת שימוש ב־CPU/GPU לפי עומס, למשל תור לבקשות בזמן עומס גבוה, כדי למנוע קריסה.

3.4 תהליכי אבטחה

מאחר שהמערכת מטפלת בתמונות המועלות על ידי משתמשים, יש לאמץ נהלי אבטחה ברורים:

1. **בדיקת קובץ לפני עיבוד** - אימות סוג הקובץ וגודלו.
2. **בדיקת קבצים ב-VT** - כל תמונה תיבדק למול VirusTotal ורק קבצים שאושרו כבטוחים ימשיכו לעיבוד במערכת.
3. **שמירה זמנית בלבד** - תמונות נמחקות לאחר הבדיקה.
4. **סינון בקשות דו־גויות** - מניעת הזרקת קוד וקבצי הרצה.
5. **הצפנת תעבורה** - שימוש ב־SSL/TLS בכל תקשורת.
6. **Rate Limit** - הגבלת מספר בקשות ממשתמש מסוים ע"מ למנוע הצפה.
7. **Journal Logs** - תיעוד פעולות Backend למעקב ותקלות.

3.5 עומסים ונפחים (Load & Capacity)

עומסים צפויים

- עד 50 משתמשים בו־זמנית בסביבה סטודנטאלית.
- עלייה ל-100-300 משתמשים בו־זמנית במקרה של פרויקט מתפתח.

נפחים


- גודל תמונה ממוצע: 200KB-4MB.
- כל בדיקה צורכת:
 - CPU לעיבוד תדירים
 - GPU לניתוח CNN
- נפח לוגים יומי ממוצע: 10MB-3MB.

3.6. תרשימי UML

● Use Case Diagram -


התרשים מציג את המשתמשים השונים של המערכת ואת הפעולות שיכולים לבצע. בנוסף מספק מבט-על על גבולות המערכת, על היכולות המרכזיות ועל האינטראקציות העיקריות בין המשתמשים לבין המערכת.

התרשים מתאר את זרימת התהליך המרכזי במערכת - החל מהעלאת התמונה, דרך בדיקות האבטחה והעיבוד המוקדם, ועד לקבלת תוצאת ה-AI בחזרה למשתמש. תרשים זה משמש להצגת השלבים הלוגיים והמעבר בין פעולות במערכת בצורה ברורה ורציפה.




Sequence Diagram - •

תרשים זה מציג כיצד רכיבי המערכת מתקשרים ביניהם בזמן אמת. הוא מדגים את סדר הקריאות בין ה-Frontend, ה-Backend, מודל ה-AI ובסיס הנתונים החל מרגע קבלת התמונה ועד יצירת תוצאה. הדיאגרמה מאפשרת להבין את הדינמיקה המערכתית והאינטראקציות בין המודולים.



Class Diagram - ●

תרשים זה מתאר את המבנה הלוגי של המערכת: המחלקות, המודולים, המאפיינים המרכזיים והקשרים ביניהם. הדיאגרמה מסייעת להבין את ארגון הקוד, מה כל רכיב מייצג ואת יחסי הגומלין בין הישויות השונות.



4. שיטה

בפרק זה נפרט את שיטת העבודה בפרויקט אשר תכלול:

- תיאור סביבת הפיתוח
- ארכיטקטורת המערכת
- כלי הפיתוח והבדיקות
- סביבת ההפעלה
- אופן התקשורת בין הרכיבים
- פרטוקולי האבטחה בהם נעשה שימוש

4.1 סביבת הפיתוח ובסיס הנתונים

4.1.1 סביבת פיתוח - צד מחקרי (מודל ה-AI)

- אימון המודלים ו-הניסויים המחקריים יתבצעו בסביבת Google Colab המאפשרת שימוש ב-GPU, עבודה בג'ופיטר נוטבוקס ושיתוף קוד בין חברי הצוות.
- ב-Google Colab נבצע:
 - טעינת ה-Datasets הרלוונטיים (תמונות Real מול Fake).
 - Preprocessing לתמונות (שינוי גודל, נירמול, יצירת ייצוגי תדר/SRM).
 - אימון מודלים שונים לזיהוי Deepfake והשוואת ביצועים ביניהם.
 - שמירת המודלים הטובים ביותר לקובץ לצורך שימוש בשרת האפליקטיבי.

4.1.2 סביבת פיתוח - צד אפליקטיבי

- פיתוח ה-Backend יתבצע בשפת Python באמצעות Flask.
- פיתוח ה-Frontend יתבצע בספריית React (JavaScript).
- סביבת העבודה המקומית תהיה VS Code אשר תשמש לעריכת קוד ה-FLASK וה-REACT.
- חלקי הקוד המחקריים (אימון מודל, ניסויים, ניתוח דאטה) יפותחו ויורצו בסביבת Google Colab המאפשרת שימוש ב-GPU וניהול מחברות קוד.
- ניהול גרסאות הקוד והעבודה המשותפת יתבצע באמצעות Git.

4.1.3 בסיס נתונים - SQLite

- בסיס הנתונים הנבחר לפרויקט הוא SQLite, בסיס נתונים קל המתאים לפרויקטי מחקר ואתרי דמו.
- בחירה זו מאפשרת להתמקד בפיתוח המודל ובתהליכי העיבוד, מבלי להקים תשתית כבדה של מסד נתונים מלא.
- ייעוד בסיס הנתונים בפרויקט
 - SQLite ישמש את המערכת בעיקר עבור:
 - תיעוד לוגים של בדיקות תמונה, כולל:
 - זמן הבדיקה
 - תוצאת המודל (Real/Fake)
 - רמת הביטחון

○ נתוני קובץ כגון גודל, פורמט ושם מקור


● **אחסון נתונים מחקריים, כגון:**

- גרסאות מודלים שנבדקו
- פרמטרים שהופעלו בתהליכי אימון
- תוצאות של ניסויים והערכות ביצועים

כיוון שהמערכת אינה כוללת מנגנון הרשאות או ניהול משתמשים, SQLite מספק פתרון יעיל וגמיש המאפשר לשמור מידע טכני ולוגים בצורה נוחה ללא צורך בשרת מסד נתונים חיצוני.

● **מבנה בסיס הנתונים -**

בסיס הנתונים כולל מספר טבלאות ייעודיות שמטרתן לתעד תוצאות עיבוד ומידע נלווה. התרשים הבא מציג את מבנה הטבלאות ואת הקשרים ביניהן:



● **תיאור הטבלאות -**

1. טבלת Users - ניהול משתמשי המערכת

טבלה זו מרכזת את המשתמשים הרשומים במערכת. הטבלה שומרת מידע בסיסי: שם משתמש ייחודי, כתובת דוא"ל, סיסמה מוצפנת (hash), תפקיד המשתמש (role), תאריך יצירה והתחברות אחרונה. שדה is_active מאפשר השבתה או הפעלה של חשבונות.

קשר: טבלת Users מקושרת לטבלת Images בקשר של 1..* - כל משתמש יכול להעלות מספר תמונות.

בנוסף, מקושרת ל-AnalysisResults לעקיבה אחר ניתוחים שביצע כל משתמש.

2. טבלת Images - שמירת התמונות שהועלו

טבלה זו מרכזת את כל התמונות המועלות למערכת. הטבלה שומרת את נתיב הקובץ, זמן העלאה, מזהה המשתמש (user_id), ואת שדה suspicious המייצג האם התמונה סומנה כחשודה על ידי בדיקות אבטחה (למשל VirusTotal או בדיקות פנימיות).

קשר: טבלת Images מקושרת לטבלת AnalysisResults בקשר של 1..* — לכל תמונה יכולים להיות מספר ניתוחים שונים.

3. טבלת AnalysisResults - תוצאות ניתוח המודל

טבלה זו שומרת את התוצאות שהתקבלו לאחר עיבוד התמונה במודל ה-AI. היא כוללת את החלטת המודל (Real/Fake), רמת הוודאות, מזהה התמונה והמשתמש, נתונים מהעיבוד המוקדם (כגון מידע ספקטרלי), וזמן הריצה של התהליך.

קשר: AnalysisResults שייכת ל-Image אחת ולמשתמש אחד. לכל תוצאה יכולים להיות Heatmaps ולוגים רבים.

4. טבלת Heatmaps - שמירת מפות אזורים חשודים

טבלה זו מרכזת את קבצי ה-Heatmap שנוצרו עבור תוצאת ניתוח מסוימת. מפות אלו משמשות להצגת האזורים שבהם המודל זיהה חריגות או עקבות עיבוד מלאכותי.

קשר: לכל תוצאת ניתוח (AnalysisResult) יכולים להיות מספר Heatmaps.

5. טבלת Logs - לוגים פנימיים של המערכת

טבלה זו מיועדת לתיעוד פעולות ה-Backend כגון: שגיאות, הצלחות, זמני עיבוד, חריגות, כתיבה לדיסק, וסימונים פנימיים נוספים.

קשר: כל רשומת Log שייכת לרשומה מסוימת בטבלת AnalysisResults. כך ניתן לעקוב אחרי כל שלבי העיבוד של כל תמונה.

מבנה בסיס הנתונים המתואר להלן הוא מבנה ראשוני אשר נועד לשמש כבסיס עבודה לתחילת הפיתוח.

מבנה זה עשוי להשתנות ולהתעדכן במהלך הפרויקט בהתאם לממצאי המחקר, לדרישות חדשות, לשינויים ארכיטקטוניים ולתוצאות בדיקות המערכת. העדכונים יתבצעו בצורה מבוקרת כחלק מתהליך הפיתוח האג'ילי, תוך שמירה על עקביות הנתונים ותיעוד גרסאות הסכימה.

4.2 ארכיטקטורה (סיכום ברמת שיטה)

הארכיטקטורה מבוססת על הפרדה בין ממשק המשתמש, השרת והמודל.

4.2.1. React) Frontend) -

אתר פשוט ופתוח ללא הרשמה המאפשר:

- העלאת תמונה.
- שליחת בקשה לבדיקה.
- הצגת תוצאה (Real/Fake + אחוז ודאות).

4.2.2. Flask) Backend) -


שרת אפליקטיבי האחראי על:

- קבלת קבצי תמונה.
- בדיקות אבטחה ותקינות לקובץ (סוג, גודל, VirusTotal).
- ביצוע Preprocessing ושליחת התמונה למודל ה-AI.
- קבלת תוצאת המודל והחזרתה ל-Frontend בפורמט JSON.
- שמירת לוגים בבסיס הנתונים SQLite.


4.2.3. מודל ה-AI

המודל יתבסס על אחד או יותר מאלגוריתמי זיהוי התמונות שנחקר במהלך הפרויקט. רכיב זה מופעל באמצעות ה-Backend ומקבל כקלט תמונה לאחר עיבוד מקדים (Preprocessing). המודל מחזיר לשרת הערכה לגבי אמיתות התמונה ורמת ביטחון מתאימה. ככל שהפרויקט יתקדם, ניתן יהיה להחליף, לשפר או להשוות בין מודלים שונים במסגרת הארכיטקטורה הקיימת.

הפרדה זו מאפשרת להתמקד במחקר המודל, תוך שמירת ממשק משתמש פשוט.



דיאגרמת ארכיטקטורה:



4.3 כלי פיתוח, כלי בדיקות ופיילוט

4.3.1 כלי פיתוח

- **Google Colab** - לאימון מודלים, ניסויים וניתוח תוצאות מחקריות.
- **VS Code** - פיתוח קוד ה-React וה-Flask.
- **Git** - ניהול גרסאות, גיבוי ושיתוף קוד בין חברי הצוות.
- **npm** - ניהול חבילות והתקנות בצד ה-Frontend.
- **pip / venv** - ניהול חבילות Python וסביבות עבודה וירטואליות ב-Backend.

4.3.2 כלי בדיקות

לצורך בדיקת תקינות המערכת, ייעשה שימוש בשילוב של בדיקות לוגיות ובדיקות ידניות. בפרויקט זה תיתכן עבודה עם מספר כלים אפשריים, בהתאם לצורך ולזמן הפיתוח:

- **בדיקות יחידה (Unit Tests)** - לבדיקת חלקי לוגיקה נבחרים בצד ה-Backend.
- **בדיקות API ידניות** - שימוש בכלים כגון Postman או Insomnia לצורך שליחת בקשות בדיקה לשרת Flask.
- **בדיקות שימושיות באתר (Frontend)** - בדיקה ידנית של תהליך העלאת תמונה בפורמטים שונים, בדיקה על תמונות Real ו-Fake מה-Dataset, תצוגת תוצאות, וטיפול בשגיאות (פורמט לא תקין, קובץ גדול מדי וכו').

הבחירה בכלי הבדיקה הספציפיים תתבצע בהתאם להתקדמות הפיתוח ולדרישות הפרויקט.

4.3.3 פיילוט ואישור אתי

- ה-Datasets שבהם נעשה שימוש הם ציבוריים ואקדמיים, לרבות סטים ייעודיים לתחום ה-Deepfake ולכן אין שימוש בתמונות פרטיות, דבר המפחית את הצורך באישור אתי פורמלי.
- במידה ויוצגו באתר תמונות לדוגמה, ייעשה שימוש בחומרים פתוחים או ב-Datasets מאושרים בלבד, תוך שמירה על פרטיות המשתמשים.
- פיילוט המערכת יתבצע באמצעות:
 - בדיקה פנימית של צוות הפיתוח, הכוללת הרצת מספר תמונות ובחינת תהליך העבודה מקצה לקצה.
 - הרצה על סט תמונות נפרד (Test Set) שלא שימש באימון, במטרה לוודא יציבות, תקינות תהליך העיבוד והתאמה בין המודל למערכת.

4.4 מערכת הפעלה וסביבת הרצה

המערכת מפותחת ומופעלת בשתי סביבות משלימות: סביבת פיתוח וסביבת הרצה.

● סביבת פיתוח

- החלק המחקרי (אימון מודלים, ניסויים וניתוח דאטה) יתבצע בסביבת Google Colab, הפועלת בענן ומספקת יכולות עיבוד מתקדמות כגון GPU.
- פיתוח המערכת האפליקטיבית יתבצע על מחשבי הפיתוח האישיים של חברי הצוות באמצעות VS Code, להרצת React ו-Flask באופן מקומי.

- סביבת הרצה (Production / Demo)

- בעת הצגת דמו או העלאה לסביבה חיצונית, המערכת תוכל לרוץ על כל שרת שתומך בהרצת Python ו-Node.js, לדוגמה:
 - שרת ענן (כגון AWS, GCP, Azure או שרת אוניברסיטאי).
 - שרת וירטואלי (VM) עם כל מערכת הפעלה נתמכת:
 - Windows Server
 - Linux
 - או כל מערכת אחרת התומכת בהרצת Flask ו-React
 - בסביבת ההרצה יופעלו:
 - שרת Flask לצורך עיבוד התמונות וקריאות ה-API.
 - קבצי ה-React לאחר בנייה אשר יוגשו כקבצים סטטיים ע"י אותו שרת או ע"י שירות אחסון סטטי.

הבחירה במערכת ההפעלה ובשרת ההרצה תתבצע בהתאם לדרישות הפרויקט, הנוחות הטכנית וזמינות המשאבים.

4.5 תקשורת

התקשורת בין רכיבי המערכת מתבצעת באמצעות REST API, המאפשר העברת נתונים בצורה פשוטה ואחידה בין ה-Frontend לבין ה-Backend.

התוצאות והמידע המוחזר מהשרת מועברים בפורמט JSON, הכולל בין היתר:

- חיווי Real/Fake
- אחוזי ודאות
- מזהה בדיקה
- פרטי שגיאה (במידת הצורך)

העלאת קובץ התמונה מתבצעת באמצעות בקשת POST בפורמט multipart/form-data, הכוללת:

- שדה קובץ (File)
- פרמטרים נלווים בהתאם לצורך

בגרסת ההפעלה המלאה (Production), כל התקשורת בין הלקוח לשרת תתבצע בפרוטוקול HTTPS, המבטיח הצפנה מלאה של המידע ועמידה בסטנדרטים בסיסיים של אבטחת מידע.

4.6 פרוטוקול אבטחה

במסגרת השיטה, המערכת תיושם עם שכבות אבטחה וניתוח פורנזי מקדים (Preprocessing Pipeline) המתאימות למערכת מחקרית המקבלת קבצים ממשתמשי קצה. שכבות אלו מיושמות בקוד השרת (Flask) ומנוהלות מול ממשק המשתמש (:React)

1. בדיקת קובץ ראשונית לפני עיבוד

- אימות סוג הקובץ : המערכת מוודאת את סיומת התמונה ותוכנה בפועל (נתמכים פורמטים כגון JPG/PNG בלבד).

- מגבלת גודל: מבוצעת בדיקת גודל מקסימלי לקובץ ע"מ למנוע עומס על משאבי השרת.

2. סריקת קבצים ואבטחה למול VirusTotal

מכיוון שהמערכת מאפשרת העלאת קבצים ממשתמשי קצה לא מזהים, היא חשופה לאיומי סייבר בסיסיים. תוקפים עשויים להעלות קבצים זדוניים (כגון סקריפטים, Web Shells או קבצי הרצה) במסווה של תמונה לגיטימיים (למשל שינוי סיומת של סקריפט מ-.php ל-.jpg) במטרה להוציא לפועל את אחת מהמתקפות הבאות:

1. **השתלטות על השרת (RCE) באמצעות Web Shells:** אם שרת ה-Flask שומר את הקובץ הזדוני ותוקף יצליח לגרום לשרת להריץ אותו, הוא יקבל גישה Terminal מלאה לתשתית המערכת. במצב כזה, התוקף יכול לגנוב את בסיס הנתונים (SQLite), למחוק את קבצי המודל או להשתמש בשרת כפלטפורמה להתקפות המשך.
2. **ניצול חולשות בספריות עיבוד תמונה (Buffer Overflows):** המודל משתמש בספריות כדי לפתוח ולנרמל את התמונה (Preprocessing). קובץ זדוני המכיל עיוותים מובנים בקוד הפיקסלים יכול לנצל חולשות ידועות בספריות אלו, לגרום לקריסת הזיכרון ולהפיל את זמינות המערכת כולה.

כדי למנוע נזקים אלו מבלי לפגוע בביצועי המודל, המערכת מיישמת שכבת הגנה הכרחית באמצעות אינטגרציה ל-VT וכל קובץ נבדק מול שירות VT טרם העברתו למודל שלנו כאשר מתבצעות הפעולות הבאות:

- **חישוב גיבוב (Hash):** בעת העלאת הקובץ ל-Backend (דרך upload_bp.post), המערכת מייצרת חותמת ייחודית לקובץ (SHA-256) באמצעות הפונקציה `calculate_file_hash`.
- **אינטגרציה ל-API:** ה-Hash נשלח ל-API של שירות VirusTotal לבדיקה מול עשרות מנועי אנטי וירוס.
- **החלטה לוגית:** רק קבצים שאושרו כבטוחים יועברו לעיבוד. אם המנועים מזהים את הקובץ כזדוני, תהליך העיבוד נעצר מיד. הקובץ מסומן כ-`blocked_malicious` במסד הנתונים, לא מועבר למודל ומוחזרת אזהרה אדומה וברורה למשתמש בממשק (Warning: Malicious File).

3. חילוץ וניתוח מטא-דאטה (EXIF Data)

בצד הפורנזי, המערכת מחלצת את נתוני המטא-דאטה המוטמנים בתמונה (EXIF) באמצעות הפונקציה `get_image_metadata`. הנתונים כוללים עקבות דיגיטליים חשובים כגון: סוג המצלמה, תוכנת העריכה, חותמת זמן (Timestamp) ונתוני מיקום (GPS). הנתונים מוחזרים לממשק בפורמט JSON. אמנם פלטפורמות להעברת מסרים (כגון WhatsApp ו-Telegram) ורשתות חברתיות מוחקות באופן אקטיבי את נתוני ה-EXIF למטרות אבטחת פרטיות וחסכון בנפח (EXIF Stripping) אך הוספת יכולת חילוץ המטא-דאטה מספקת יתרון פורנזי משמעותי במספר תרחישים:

- **חקירת מקורות ראשוניים:** עיתונאים וחוקרי מודיעין מקבלים לא פעם תמונות ממקורות מקוריים (למשל העברה במייל מגורם בשטח, הורדה מכון או שליחה כ"קובץ/מסמך" ללא כיווץ).

בתרחישים אלו, המטא-דאטה נשמר במלואו ומאפשר לאמת את מכשיר הצילום והמיקום הגיאוגרפי.

- **זיהוי סתירות:** כאשר מטא-דאטה קיים הוא מאפשר הצלבה קריטית. אם תמונה מתיימרת להציג אירוע מהיום אך חותמת הזמן מראה שצולמה לפני חמש שנים, או שהמיקום מצביע על מדינה אחרת - נחשף הזיוף ההקשרי (Out-of-Context), גם אם התמונה עצמה לא זויפה ע"י AI. מציאת שם של תוכנת עריכה (כמו Photoshop או תוכנות AI גנרטיביות) בשדה ה-Software מהווה אינדיקציה לעיבוד מלאכותי.
- **היעדר מטא-דאטה כראייה נסיבתית:** גם כאשר המטא-דאטה חסר, המידע בעל ערך. אם משתמש טוען שהרגע צילם את התמונה בטלפון שלו אך המערכת מציגה שדות EXIF ריקים, עולה חשד כבד שהתמונה אינה מקורית ועברה הלבנה או הורדה מרשת חברתית.

4. הצפנת תעבורה והגנה מפני עומסים

- **הצפנת תעבורה:** בעבודה על שרת חיצוני, כל התקשורת תתבצע בפרוטוקול HTTPS לאבטחת המידע העובר ברשת.
- **Rate Limiting:** הגבלת כמות הבקשות פר כתובת IP/משתמש בזמן נתון, כדי למנוע מניעת שירות (Dos קטן) והצפות על המערכת.

5. ניהול לוגים, היסטוריה ושמירה זמנית

- **Journal Logs והיסטוריית סריקות:** כל תוצאות הסריקה, המטא-דאטה והחלטות המודל נשמרות בטבלת ScanLog במסד הנתונים (SQLite), לצורך ניתוח תקלות ושיפור ביצועים. המערכת מאפשרת למשתמש לצפות בהיסטוריית הסריקות שלו דרך ממשק ה-Dashboard.
- ברמת השרת, פותחה התאמה לאזור הזמן המקומי (ישראל) באמצעות הוספת הסטה של 3 שעות ($3 = \text{timedelta(hours)}$) לזמן השמירה המקומי (UTC), להבטחת תצוגה עקבית.
- **שמירה זמנית בלבד:** תמונות יישמרו בשרת לפרק זמן מוגבל של עד 30 יום לצורכי בקרה ומחקר, שבסיומם יופעל מנגנון מחיקה אוטומטי למזער סיכוני פרטיות.

6. Journal Logs

- שמירת לוגים של פעולות Backend בבסיס הנתונים SQLite, לצורך ניתוח תקלות ושיפור ביצועים, בהתאם לסעיפי ניהול הלוגים שהגדרתם.

7.4. הגישה שלנו לפתרון הבעיה -

כדי להתמודד עם המורכבות של זיהוי זיופי AI מודרניים, המערכת מיישמת ארכיטקטורת **Ensemble Learning**. במקום להסתמך על מודל בודד, המערכת משלבת מספר מודלים המבצעים ניתוח מזוויות משלימות, מה שמגביר את חוסן המערכת אל מול מניפולציות מגוונות.

המערכת מתבססת על שלושה צירי ניתוח ופלט מרכזיים:

- **Spatial Analysis:** שימוש ב-0EfficientNetB - רשת קלת-משקל עם Transfer Learning מ-ImageNet - ללמידת מאפיינים ויזואליים ואי-התאמות במרקם ובפרופורציות של התמונה.
הערה: בשלב מוקדם נבחנה ארכיטקטורת Xception, אך עקב עומס זיכרון GPU חמור שגרם לקריסת השרת לאחר שני epochs בלבד, הוחלט לעבור לארכיטקטורות קלות-משקל.

- **Frequency Analysis:** שימוש במודל SRM-CNN לזיהוי דפוסים סטטיסטיים ורעשים שאינם נראים לעין אנושית, תוך חילוץ "חתימות דיגיטליות" של מודלי AI.
- **Heatmaps:** להגברת שקיפות המערכת, המודל מפיק Heatmaps המדגישים את האזורים החריגים בתמונה. כלי זה מאפשר למשתמש להבין את הנימוק הוויזואלי מאחורי החלטת המודל.

מאגר הנתונים לאימון המודל -

לצורך אימון ובחינת המערכת, נבנה מאגר נתונים נרחב הכולל כ-312,000 תמונות. המאגר מורכב משלושה מקורות עיקריים להבטחת יכולת הכללה גבוהה:

- **OpenForensics:** מאגר ממוקד בזיהוי פנים וזיופי Deepfake מורכבים.
- **CIFAKE:** מאגר המשלב תמונות שנוצרו במודלי Diffusion ו-GAN אל מול תמונות אמת.
- **CustomWar:** מאגר ייחודי שנאסף ונבנה באופן עצמאי ע"י צוות הפרויקט הכולל תמונות מהקשרים מלחמתיים וביטחוניים, במטרה להתאים את המערכת לאתגרי השעה ולתרחישי האמת. לאור חשיבותו, מאגר זה הורחב פי 5 ביחס לגרסתו הראשונית על מנת לחשוף את המודל לגיוון רב יותר ולמנוע Overfitting לדפוסים ספציפיים. המאגר מכיל:
- **תמונות REAL -** התמונות נאספו בקפידה ממקורות פומביים ואמינים, כגון אתר ודובר צה"ל (כולל ערוץ ה-Flicker הרשמי), אוסף התצלומים הלאומי של לשכת העיתונות הממשלתית ואתרי חדשות (תחת שימוש הוגן וסעיף 27א'). פירוט מלא על המקורות וזכויות היוצרים נמצא בנספח זכויות היוצרים של הפרויקט.
- **תמונות FAKE -** סונתחו באופן מבוקר ע"י צוות הפרויקט באמצעות מודלים גנרטיביים מתקדמים (Diffusion Models), כדי לדמות זיופים ברמת אמינות גבוהה המאפיינים לוחמה פסיכולוגית והפצת דיסאינפורמציה בזמן לחימה.
- **CelebDF v2:** מאגר המכיל סרטוני וידאו של ידוענים אמיתיים וגרסאות מזויפות שלהם. מהסרטונים מחולצים פריימים בקצב של פריים לשנייה, כך שכל פריים מטופל כתמונה עצמאית. נוסף במכוון מסיבות שתיים: להכביד על המודל ולחשוף אותו לזיופי פנים איכותיים שאינם קיימים במאגרים האחרים, ולהפחית Overfitting באמצעות גיוון מקור הנתונים (פריימי וידאו לעומת תמונות סטילס).

חלוקת הנתונים מתבצעת ליחס של 80% לאימון, 10% לולדיציה ו-10% לסט המבחן.

תהליך אימון המודל -

תהליך האימון מתוכנן להתבצע בשני שלבים מרכזיים:

1. **שלב ה-Base Models:** אימון נפרד של שלושה מודלים: CNN-SRM (ניתוח תחום הרעש והתדרים), EfficientNetB (ניתוח מרקם ומאפיינים ויזואליים סמנטיים), ו-Two-Stream (מודל משולב המאחד את שני הזרמים). הבחירה בארכיטקטורות קלות-משקל נבעה מאילוצי משאבי שרת. בשלב זה מתבצעת בקרה קפדנית למניעת Data Leakage בין קבוצות הנתונים.
2. **שלב ה-Ensemble (Fusion):** זהו המודל הסופי של המערכת, שילוב הפלטים של CNN-Weighted Two-Stream ו-OSRM, EfficientNetB לכדי החלטה סופית אחת באמצעות

Ensemble. ה- Two-Stream הוא רכיב בתוך ה- Ensemble ולא המוצר הסופי. בשלב זה מבוצע Weights Tuning אופטימלי המבוסס על ביצועי המודלים בסט התיקוף (Validation Set).


מדדי הערכה ובקרה -

בקרת האימון והערכת התוצאות מבוצעות באמצעות:

- **מטריצת בלבול (Confusion Matrix):** לניתוח מדויק של שיעורי ה- False Positive וה- False Negative.
- **מדדי Precision ו- Recall:** בדגש על יכולת איתור זיופים גבוהה.
- **ניתוח מפות חום:** יודא שהמודל אכן מתמקד באזורים הרלוונטיים לזיוף (כמו עיוותי פיקסלים או שולי פנים) ולא בפרטים מקריים ברקע.

תוצאות והערכת ביצועים-


נכון לשלב זה של הפרויקט, ביצענו סדרת בדיקות מקיפה על סט הבדיקה (Test Set) כדי להעריך את יכולות הזיהוי של המערכת אל מול מאגר הנתונים הנרחב.



להלן ריכוז הממצאים והתובנות המרכזיות:

- **ביצועי המערכת בזיהוי תוכן:** המערכת השיגה רמת דיוק (Accuracy) של 67.24%. מדד ה-AUC, העומד על 0.7447, מעיד על יכולת הפרדה טובה ומבטיחה בין תמונות אותנטיות לתמונות שנוצרו על ידי בינה מלאכותית.
- **דגש על איתור זיופים (Recall):** המערכת מראה רגישות גבוהה במיוחד לזיהוי תוכן מזויף (FAKE) עם מדד Recall של 0.7522. משמעות הדבר היא שבתצורתה הנוכחית, המערכת כבר מצליחה לאתר נכונה כ-75% מכלל התמונות המזויפות בסט הבדיקה.
- **מטריצת בלבול (Confusion Matrix):** המערכת סיווגה בהצלחה 11,652 תמונות מזויפות ו- 9,292 תמונות אמיתיות. הנתונים מצביעים על נטייה של המערכת ל"זהירות יתרה" (שאיפה ל-High Recall), מה שמבטיח סינון אפקטיבי של תוכן מטעה.

מרכיב מחקרי -



בנוסף לפיתוח מערכת ה-

Ensemble הסופית, הפרויקט כולל מרכיב מחקרי עצמאי המתבצע במקביל באמצעות שלוש מחברות ניסויים נפרדות שכל אחת מהן מכילה מודל אחר - OCNN-SRM, ViT, efficientnetB0. כל מחברת בוחנת ארכיטקטורה שונה בתנאים זהים: כל מודל מאומן בנפרד על כל אחד מארבעת מאגרי הנתונים ולאחר מכן נבחן על כלל המאגרים. התוצאות יוצגו כמטריצת ביצועים 4x4 עבור כל מדד (AUC, Accuracy, Precision, Recall, F1). בהתאם לתוצאות תתקבל החלטה האם לבנות Ensemble נוסף מהניסויים בנפרד, ובנוסף תיבדק האופציה תוצאות הניסויים ישמשו גם בבסיס לאופטימיזציית משקלות ה-Ensemble הסופי.

בקרת איכות הלמידה -

בחינת התפלגות ציוני החיזוי (Prediction Score Distribution) מראה כי המערכת מגיעה להחלטות חד-משמעיות ומובהקות ברוב המקרים (ציונים הקרובים לקצוות 0 ו-1). יציבות זו מעידה על כך שהמודל לומד דפוסים אמיתיים ומבסס את החלטותיו על מאפיינים ברורים שנמצאו בנתונים.

תוכנית עבודה - גאנט

קישור לג'ירה

קישור לגיט

8.4. מדדי הצלחה של המערכת הסופית - המערכת תיחשב מוצלחת אם תעמוד בכל הקריטריונים הבאים עד יוני 2026:

- 1. Accuracy מעל 85%
- 2. AUC מעל 0.90 על Test Set מאוחד של מודל ה-Ensemble
- 3. זמן עיבוד תמונה בודדת מתחת ל-3 שניות
- 4. ממשק משתמש פונקציונלי המאפשר העלאת תמונה וקבלת תוצאה עם Heatmap.
- 5. יציבות ואבטחת הקלט - המערכת תבטיח סינון של 100% מהקבצים המזהים כזדוניים ע"י VirusTotal לפני הגעתם לשכבת העיבוד ובכך תמנע פגישה בתשתית השרת.

תוצאות CNN-SRM - Baseline (לפני שיפורי מאגר הנתונים)

מדד	ערך
AUC	0.71
Accuracy	67.24%
Recall (FAKE)	0.75
True Positive (Fake נכון)	13,758
False Negative (Fake שסווג כ-Real)	1,821
False Positive (Real שסווג כ-Fake)	5,886
True Negative (Real נכון)	9,647

אלו תוצאות Baseline בלבד שהתקבלו לפני הרחבת מאגר CustomWar ולפני הוספת המאגר-CelebDF. ההרצה הנוכחית צפויה להניב תוצאות משופרות.

תוצאות CNN-SRM (הרצה נוכחית)

מדד	ערך
AUC	
Accuracy	
F1 (FAKE)	
Precision	
Recall (FAKE)	
True Positive (Fake נכון)	

לא בטוח שנצטרך למלא אותם: הערות עם [4]
בהרצה הבאה צריך לראות את התוצאות

- [5] **הערות עם** לא בטוח שנצטרך למלא אותם בהרצה הבאה צריך לראות את התוצאות
- [6] **הערות עם** לא בטוח שנצטרך למלא אותם בהרצה הבאה צריך לראות את התוצאות
- [7] **הערות עם** לא בטוח שנצטרך למלא אותם בהרצה הבאה צריך לראות את התוצאות

	False Negative (Fake שסווגו כ Real)
	False Positive (Real שסווגו כ Fake)
	True Negative (Real זוהו נכון)

תוצאות - EfficientNetB0

ממד	ערך
AUC	
Accuracy	
F1 (FAKE)	
Precision	
Recall (FAKE)	
True Positive (Fake זוהו נכון)	
False Negative (Fake שסווגו כ Real)	
False Positive (Real שסווגו כ Fake)	
True Negative (Real זוהו נכון)	

תוצאות - Two-Stream

ממד	ערך
AUC	
Accuracy	
F1 (FAKE)	
Precision	
Recall (FAKE)	
True Positive (Fake זוהו נכון)	
False Negative (Fake שסווגו כ Real)	

	False Positive (Real שסווג כ Fake)
	True Negative (Real נכון)

תוצאות Weighted Ensemble - מודל סופי

ממד	ערך
AUC	
Accuracy	
F1 (FAKE)	
Precision	
Recall (FAKE)	
משקל CNN-SRM	
משקל EfficientNetB0	
משקל Two-Stream	

5. מחקר:

ניסויים השוואתיים לבחינת יכולת הכללה חוצת-מאגר

5.1 שאלת המחקר והשערות

במסגרת הפרויקט בוצעה סדרת ניסויים מחקריים שמטרתם לבחון את יכולת ההכללה (Generalization) של ארכיטקטורות שונות לזיהוי Deepfake.

שאלת המחקר המרכזית היא: האם מודל למידה עמוקה שאומן על מאגר נתונים אחד שומר על ביצועי זיהוי מהימנים כאשר הוא נבחן על מאגר נתונים שונה שלא נכלל בתהליך האימון (Cross-Database Generalization)?

השערת המחקר: מודלים המתמקדים בניתוח תחום התדירים ודפוסי רעש (CNN-SRM) יפגינו יכולת הכללה גבוהה יותר בהשוואה למודלים המתמקדים בניתוח ויזואלי סמנטי (EfficientNetB0, ViT-Light), מאחר שחתימות הרעש של מודלים גנרטיביים אינן תלויות בתוכן הוויזואלי של התמונה.


מדד הצלחה מחקרי: הניסוי יחשב מוצלח אם לפחות אחד מהמודלים יפגין יציבות חוצת-מאגר. כלומר, הפרש של פחות מ-10% ב-AUC בין ביצועים תוך-מאגר (Within-Database) לביצועים בין-מאגר (Cross-Database). פער גדול מ-10% יצביע על התאמת-יתר (Overfitting) למאגר האימון ויספק תובנה מחקרית לגבי מגבלות אותה ארכיטקטורה.

5.2 עיצוב הניסוי - מתודולוגיה

כל אחד משלושת המודלים - ViT-Light, EfficientNetB0 ו-CNN-SRM - אומן בנפרד על כל אחד מארבעת מאגרי הנתונים: CelebDF, OpenForensics, CiFake, CustomWar. לאחר האימון, כל מודל נבחן על כלל ארבעת המאגרים, כולל אלו שלא שימשו לאימון. התוצאות מוצגות כמטריצת ביצועים 4x4 עבור כל מדד (AUC, Accuracy, F1-FAKE). גישה זו מאפשרת להפריד בין ביצועים תוך-מאגר (Within-Database) לביצועים בין-מאגר (Cross-Database), ולהעריך את חוסן כל ארכיטקטורה לנתונים שלא נראו באימון.

הכללת CelebDF v2 בניסויים נועדה לבחון האם מאגר המבוסס על פריימי וידאו משפר את יכולת ההכללה הצולבת בהשוואה למאגרים המבוססים על תמונות סטילס בלבד.
זוהי שאלת מחקר משנית הנבחנת במסגרת הניסויים.

צריכים לראות אם אנחנו רוצים: **הערות עם [8]**
לעשות שאלת מחקר משנית- לבדוק עם אירינה ואלונה



5.3 תוצאות הניסויים

5.3.1 תוצאות CNN-SRM

מטריצת AUC - Cross-Database

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

מטריצת Accuracy - Cross-Database

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar

				CelebDF
				Combined

F1-FAKE — Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

0EfficientNetB תוצאות 5.3.2

AUC - Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

Accuracy - Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
---------	-----------	--------	---------------	---------------

				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

F1-FAKE — Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

5.3.3 תוצאות ViT-Light

AUC - Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

מטריצת Accuracy - Cross-Database

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

F1-FAKE — Cross-Database מטריצת

CelebDF	CustomWar	CiFake	OpenForensics	אומן ↓ נבדק ←
				OpenForensics
				CiFake
				CustomWar
				CelebDF
				Combined

5.3.4 ניתוח השוואתי - כל הקומבינציות האפשריות

הטבלה הבאה מרכזת את כל זוגות האימון-בדיקה האפשריים (12 קומבינציות Cross-Database) עבור כל שלושת המודלים:

F1-FAKE	Accuracy	AUC	נבדק על	אומן על	מודל
			CiFake	OpenForensics	CNN-SRM
			CustomWar	OpenForensics	
			CelebDF	OpenForensics	
			OpenForensics	CiFake	
			CustomWar	CiFake	
			CelebDF	CiFake	
			OpenForensics	CustomWar	
			CiFake	CustomWar	
			CelebDF	CustomWar	
			OpenForensics	CelebDF	
			CiFake	CelebDF	
			CustomWar	CelebDF	
			CiFake	OpenForensics	EfficientNetB0
			CustomWar	OpenForensics	
			CelebDF	OpenForensics	
			OpenForensics	CiFake	
			CustomWar	CiFake	
			CelebDF	CiFake	

			OpenForensics	r	
			CiFake	CustomWar	
			CelebDF	CustomWar	
			OpenForensics	CelebDF	
			CiFake	CelebDF	
			CustomWar	CelebDF	
			CiFake	OpenForensics	ViT-Light
			CustomWar	OpenForensics	
			CelebDF	OpenForensics	
			OpenForensics	CiFake	
			CustomWar	CiFake	
			CelebDF	CiFake	
			OpenForensics	CustomWar	
			CiFake	CustomWar	
			CelebDF	CustomWar	
			OpenForensics	CelebDF	
			CiFake	CelebDF	
			CustomWar	CelebDF	

5.3.5 סיכום יכולת הכללה לפי מודל

מודל	AUC ממוצע Within-DB	AUC ממוצע Cross-DB	פער ממוצע	עמידה במדד הצלחה (פחות מ-10%)
CNN-SRM				
EfficientNetB0				
ViT-Light				

5.4 ניתוח ומסקנות

— להשלים עם השלמת כלל הניסויים —

5.5 החלטה על Ensemble מחקרי

בהתאם לתוצאות סעיף 5.3 תתקבל החלטה האם לבנות Ensemble המשלב את שלושת מודלי הניסויים. ההחלטה תתבסס על רמת המתאם בין טעויות המודלים ועל השיפור הצפוי ביחס לעלות הנוספת.

ייתכן שבסוף התהליך יתקיים Ensemble אחד מאוחד הכולל את כלל המודלים משתי המחברות, או שיישאר שני תוצרים נפרדים - אחד מחקרי ואחד יישומי.

סקירת מאגר הנתונים




במסגרת הפרויקט נבנה מאגר נתונים משולב לצורך אימון, ולידיעה ובדיקת המודלים. המאגר כולל תמונות ממספר מקורות שונים, במטרה להגדיל את הגיוון של הנתונים ולשפר את יכולת ההכללה של המודל על תמונות שלא הופיעו בתהליך האימון.

המאגר מורכב מ-4 מקורות: CelebDF v-2, OpenForensics, CiFake, CustomWar. כל מאגר מייצג סוג שונה של נתונים, כגון זיופי פנים מבוססי GAN, תמונות AI שנוצרו באמצעות GAN/Diffusion, תמונות מלחמה ופריימים מסרטוני וידאו. שילוב מקורות אלו נועד לחשוף את המודל למגוון רחב יותר של תרחישים וסוגי זיופים.

בסה"כ המאגר כולל 405,525 תמונות, מתוכן 172,061 תמונות Real ו-233,464 תמונות Fake. מאחר שקיים חוסר איזון בין המחלקות, הוגדרו משקלי מחלקות בתהליך האימון כך שהמודל יתייחס בצורה מאוזנת יותר לשתי המחלקות ולא ייטה לטובת המחלקה הגדולה יותר. הנתונים חולקו ל-Train, Validation ו-Test כאשר סט האימון שימש ללמידת המודל, סט הוולידציה שימש לבחינת ביצועים במהלך האימון וסט הבדיקה נשמר להערכת ביצועים סופית.

בנוסף, בוצע Resize אחיד לתמונות: תמונות RGB הותאמו לגודל 224×224 ועבור SRM התמונות הותאמו לגודל 256×256.

מאגר נתונים	סוג	פורמט	REAL	FAKE	סה"כ	Train	Val	Test
OpenForensics	פנים סינתטיות (GAN)	JPG	95,201	95,134	190,335	140,002	39,428	10,905
CiFake	תמונות AI (Diffusion/GAN)	JPG	60,000	60,000	120,000	100,000	20,000	—
CustomWar	תמונות מלחמה (Diffusion)	JPG/PNG	4,455	4,767	9,222	7,100	1,061	1,061
CelebDF v2	פריימים מוידא (פייסוואפ)	JPG	12,405	73,563	85,968	71,297	7,796	6,875
סה"כ			172,061	233,464	405,525	318,399	68,285	18,841



6. תוצרי המערכת והמחשת הממשק


בפרק זה יוצג הממשק הגרפי של מערכת RealEyes, אשר פותח באמצעות ספריות React מתקדמות (כגון Framer Motion לאנימציות ו-Lucide Icons לוויזואליזציה). הממשק עוצב בסגנון "Dark Mode" מודרני עם אלמנטים צפים תוך שימת דגש על חוויית משתמש (UX) חלקה, נגישות ושקיפות מלאה של התהליכים הפורנזיים למשתמש הקצה.

6.1 מערכת הזדהות ובקרת גישה (Authentication System)



מערכת הכניסה וההרשמה מהווה את חומת המגן הראשונה של המערכת. כדי להבטיח אבטחת מידע מחמירה, המערכת כוללת בדיקות תקינות (Validation) בזמן אמת בצד הלקוח (למשל, וידוא עמידה בדרישות סיסמה של 8 תווים, אותיות רישיות, מספרים ותווים מיוחדים). כמו כן מתבצעות במקביל בדיקות מול השרת למניעת כפילויות של שמות משתמש וכתובות אימייל של משתמשים רשומים כבר למערכת.

בנוסף להרשמה הרגילה, המערכת תומכת בהתחברות מאובטחת ומהירה באמצעות חשבון גוגל (Google SSO), המייצרת באופן אוטומטי משתמש מקומי מאומת במסד הנתונים. בעת הרשמה, נדרש המשתמש לאשר את תקנון המערכת המפרט את מדיניות השמירה הזמנית של קבצים למשך 30 יום והאיסור על שימוש לרעה במערכת.


מסך ההתחברות של המערכת:
(התחברות רגילה + התחברות דרך חשבון גוגל)




מסך ההרשמה של
המערכת:



חלונית תנאי השימוש המחייבת אישור בטרם יצירת חשבון:






6.2 מנגנון שחזור סיסמה מאובטח (Password Recovery)


מתוך הבנת הצורך במערכת עצמאית ואמינה, פותח מנגנון מלא לשחזור סיסמה. משתמש ששכח את סיסמתו מזין את כתובת האימייל שלו ושרת ה-Backend מחולל אסימון הרשאה (JWT Token) ייעודי ומוצפן, בעל תוקף קצר של 15 דקות בלבד למניעת ניצול לרעה. האסימון נשלח ללקוח באמצעות דוא"ל הכולל קישור ייחודי לאיפוס הסיסמה.

מסך בקשת שחזור סיסמה:




המייל שנשלח
למשתמש:
(המייל כולל קישור
מוגבל בזמן לאיפוס
סיסתו)

מוצפן




מסך הגדרת הסיסמה החדשה :



6.3 לוח הבקרה הראשי והדרכת משתמשים (Dashboard & System Guide)

לוח הבקרה מהווה את ליבת המערכת. הוא תוכנן להיות מינימליסטי ואינטואיטיבי כך שהמשתמש יוכל להעלות תמונה לבדיקה בלחיצת כפתור. כדי להגיש את המושגים הטכניים למשתמשים שאינם סייבר, שולב כפתור "System Guide" מרחף. לחיצה עליו פותחת חלונת מידע המסבירה בשפה ברורה כיצד מתבצעת סריקת הנוזקות (VirusTotal), מה המשמעות של אחוזי הביטחון של המודל (Model Confidence) וכיצד לקרוא את נתוני המטא-דאטה.


מסך ה-Dashboard:



מסך ה-
Dashboard לאחר
סריקה:

ביצוע

חלונית המידע המסבירה על התהליכים והמושגים:




6.4 ניתוח תוצאות, פורמטיקה וסריקת נזקות (Analysis & Metadata)

מיד עם העלאת הקובץ, המערכת משדרת אינדיקציה ויזואלית על תהליך האנליזה ("Analyzing Image..."). בשלב זה השרת סורק את הקובץ. תוצאת האנליזה מוצגת בשני אופנים עיקריים הממחישים את שכבות ההגנה של המערכת:

א. **חסימת קבצים דוניים (Malware Detection):** אם מנועי VirusTotal מזהים את הקובץ כדדוני, תהליך העיבוד של המודל נעצר באופן מיידי למניעת פגיעה בשרת. המשתמש יקבל אזהרה אדומה בולטת ("Warning: Malicious File").

ב. **ניתוח תמונה ומטא-דאטה (Metadata Extraction):** כאשר הקובץ תקין, המערכת מציגה את החלטת המודל (Fake/Real) לצד אחוזי הביטחון (Confidence). במקביל, מוצגת טבלת מטא-דאטה (EXIF) המכילה את העקבות הדיגיטליים של התמונה. יתרון בולט של המערכת הוא שימוש בספריית geopy ו-Nominatim Reverse Geocoding הממירה באופן אוטומטי קואורדינטות של GPS לשמות מובנים של עיר ומדינה ובכך מקלה על הניתוח הפורמטי של המשתמש. כמו כן, המערכת מזהה האם התמונה עברה שינוי ממדים (Resizing).




תוצאות של תמונה לדוגמא שצולמה בטלפון האישי:



6.5 ניהול פרופיל והיסטוריית סריקות (Profile & Scan History)


אזור הפרופיל מאפשר למשתמש לנהל את החשבון שלו. דרך ממשק זה ניתן לשנות סיסמה בצורה מאובטחת. משתמשים שהתחברו דרך Google יקבלו חיווי מתאים כי ניהול הסיסמה שלהם מתבצע חיצונית. בנוסף, המשתמש יכול לגשת ל"היסטוריית סריקות" (Scan History) המציגה את כלל הקבצים שהעלה בעבר.

מסך הפרופיל:



6.6 גישות והתאמה לתקני אינטרנט (Accessibility)


מתוך תפיסה שהמערכת צריכה לשרת מגוון רחב של משתמשים, לרבות משתמשי קצה בעלי מוגבלויות, הושם דגש על הנגשת ממשק המשתמש (UI). התוסף מאפשר הנגשה והתאמה דינמית של הממשק לצרכי המשתמש. גישה זו מבטיחה שכל אדם יוכל להפעיל את מערכת RealEyes ולקבל אינדיקציה מהימנה ללא חסמים פיזיים או טכנולוגיים.



6.7 הצגת Heatmap להחלטת המודל

בנוסף להצגת החלטת המודל ואחוזי הביטחון, שולבה במערכת גם תצוגת Heatmap המאפשרת להציג למשתמש הסבר חזותי לתוצאת הסריקה. מפת החום מדגישה את האזורים בתמונה שהיו משמעותיים יותר בתהליך קבלת ההחלטה של המודל.

באמצעות תצוגה זו המשתמש אינו מקבל רק תוצאה סופית של Real או Fake, אלא גם אינדיקציה ויזואלית המסייעת להבין אילו אזורים בתמונה השפיעו יותר על הסיווג. אזורים המודגשים בצבעים חמים יותר מייצגים אזורים בעלי תרומה גבוהה יותר להחלטת המודל, בעוד אזורים פחות מודגשים תרמו פחות לתוצאה הסופית.





שילוב ה-Heatmap מחזק את שקיפות המערכת ומצמצם את תחושת ה"קופסה השחורה" של המודל, מאחר שהוא מאפשר למשתמש להבין בצורה ברורה יותר את הבסיס החזותי שעליו נשענה ההחלטה. יכולת זו חשובה במיוחד במערכת לזיהוי Deepfake, שבה יש משמעות לא רק לשאלה האם התמונה סווגה כאמינית או מזויפת אלא גם להבנת הסיבה שהובילה לסיווג זה.

רשימת מקורות (References) -

- Heidari, A., Navimipour, N. J., Dag, H., & Unal, M. (2023). Deepfake detection using deep learning methods: A systematic and comprehensive review. *WIREs Data Mining and Knowledge Discovery*, 13(6), e1520.
- Li, R., Zhang, W., & Liu, Y. (2024). DAFSVFND: Dual Attention Fusion Network for Fake News Detection on Short Video Platforms. In *Proceedings of the 32nd ACM International Conference on Multimedia*.
- Nguyen-Le, H.-H., Tran, V.-T., Nguyen, D.-T., & Le-Khac, N.-A. (2025). Passive Deepfake Detection: A Comprehensive Survey across Multi-modalities. *arXiv preprint arXiv:2411.17911*.
- Pasquini, C., Amerini, I., & Boato, G. (2021). Media forensics on social media platforms: A survey. *EURASIP Journal on Information Security*, 2021(4).
- Wang, T., Liao, X., Chow, K. P., Lin, X., & Wang, Y. (2024). Deepfake Detection: A Comprehensive Survey from the Reliability Perspective. *arXiv preprint arXiv:2211.10881*.
- Ye, X., Sui, M., Zeng, M., Han, Z., & Wang, H. (2024). Frequency domain characteristics and optimization of image generation for GANS. *Research Square*.

נספח מקורות וזכויות יוצרים

מאגר הנתונים (Dataset) בפרויקט זה נבנה לצרכים אקדמיים ומחקריים בלבד. השימוש בתכנים נעשה בהתאם לדיני זכויות יוצרים ולתנאי "שימוש הוגן".

מקורות המידע וזיהוי קבצים

מאגר התמונות האמיתיות (Real) נאסף ממספר מקורות פומביים שונים. לצורך זיהוי המקור ושמירה על זכויות היוצרים, כל קובץ במאגר קיבל שם ייחודי המעיד על מקורו.

להלן מפתח המקורות עבור קבצי המאגר:

תמונות אמיתיות :

1. אתר צה"ל ודובר צה"ל והערוץ הרשמי ב-Flicker

• זיהוי בקבצים:

○ תמונות מאתר צה"ל: il_jdf_[מספר סידורי]

○ תמונות מערוץ הפליקר (idf_flickr): [מספר סידורי]

- בעלי הזכויות: צבא ההגנה לישראל / משרד הביטחון.
- תנאי שימוש:

○ אתר צה"ל: השימוש נעשה בהתאם לתקנון האתר, המתיר "שימוש הוגן" ביצירות המוגנות למטרות לא-מסחריות.


○ Flickr תמונות אלו משוחררות תחת רישיון בינלאומי מסוג CC BY-SA 2.0 (Creative Commons Attribution-ShareAlike), המתיר שימוש, הפצה ועיבוד בכפוף למתן קרדיט.

- קישורים למקור: IDF Flickr Photostream | <https://www.idf.il>

2. אוסף התצלומים הלאומי (לשכת העיתונות הממשלתית)

- זיהוי בקבצים: תמונות שמקורן באוסף התצלומים הלאומי מסומנות במאגר תחת התבנית: gpophotoheb.gov.il_ [מספר סידורי] (לדוגמה gpophotoheb.gov.il_0001.jpg).
- בעלי הזכויות: מדינת ישראל / משרד ראש הממשלה.
- תנאי שימוש: השימוש נעשה בהתאם לרישיון השימוש באתר לע"מ, המתיר העתקה ושימוש בתמונות למטרות לא-מסחריות וללא פעילות מפלגתית. לא נעשה שימוש בתמונות המסומנות ב- "Copyright held by the photographer" © אשר הוחרגו מתנאי הרישיון.
- חובת קרדיט: בכל שימוש ויזואלי בתמונה (כגון במצגת או בספר הפרויקט), יצוין במפורש: "צילום: [שם הצלם], לשכת העיתונות הממשלתית".
- קישור למקור: <https://gpophotoheb.gov.il>

האישור שניתן במייל:



ממקורות
(סעיף 27א -

3. תמונות
עיתונאיים
בעל זכויות לא ידוע)

- מקור: אתר החדשות "כיפה".
- זיהוי בקבצים: תמונות אלו מסומנות במאגר תחת התבנית: news_27a_ [מספר סידורי]
- בעלי הזכויות: זהות הצלם אינה ידועה.
- תנאי שימוש: השימוש בתמונות אלו נעשה בהסתמך על סעיף 27א לחוק זכות יוצרים (שימוש ביצירה שבעל זכות היוצרים בה אינו ידוע), כפי שפורסם במקור ובמסגרת "שימוש הוגן" לצרכי מחקר אקדמי.
- קרדיט: במידה וייעשה שימוש ויזואלי בתמונה, יצוין: "צילום: לא ידוע (שימוש לפי סעיף 27א), באדיבות אתר כיפה".

אנו מצהירים כי השימוש בתכנים המוגנים נעשה ללא שינויים הפוגעים בערך היצירה או בכבוד המצולמים, וכי בכל הצגה פומבית של הפרויקט (מצגת/ספר) יינתן הקרדיט הראוי למקורות אלו כנדרש.